

Stochastic Processes
(Prince's Edition: By **Abdelrhman Elbreens**)

Lec1to9

Made Possible by:



Lec1: Introduction to Random (Stochastic) Processes

1. كل حاجة بتبدأ بال**random variables** لو طلبت منك تجيب جنيه فضة وترميه مرتين... تفتر ممك يطلع معاك كام مرة كتابة؟ ممك ميطلعش معاك كتابة اصلاً، وممك يطلع معاك المرتين كتابة، وممك مرة فيهم تطلع صورة ومرة تطلع كتابة عادي.
لو قولنا علي الملك H (يعني head) وعلى الكتابة T (يعني tail) هتبقي احتمالات اني ارمي الجنيه مرتين ورا بعض كالأتي (الـ S دي فضاء العينة او الـ sample space بتاعتي):

$$S = \{ HH, HT, TH, TT \}$$

احنا كل ده عايزين احتمالات ايه الاول؟ ان يطلع معايا كام كتابة في المرتين. طب ما جميل او اي احنا نرمز للعدد ده بـ x ، ونحط احتمالات كام كتابة تطلع معايا في جدول (بنسمى الجدول او الرصدة دي الـ probability mass function او الـ PMF):

x	0	1	2
$P(X = x)$	0.25	0.5	0.25

معني ان كتابة واحدة طلعت مرتين (او نص الاحتمالات S)، وكتابتين طلعت معايا مرة واحدة (ربع S) وولا كتابة طلعت معايا مرة واحدة برضه. دلوقتي بقى الـ X دي **random variable** بتاعي، وهبيقي يا اما 0 يا 1 يا 2:

$$X = x \in \{0, 1, 2\}$$

وطبعاً مش هوصيك ان انا ممكن اخد الـ $E(X)$ والـ $Var(X)$ لـ X بس مش موضوعنا دلوقتي.

2. طب لو حطيت الـ **time** مع الـ **random variable**

خلينا علي مثال بسيط بعيد عن ان الـ **random variable** فيه جه ازاي: حاجة زي الطقس بتاع كل يوم كان عامل ازاي (يعني هيطلع مشمس او غائم او ممطر وهكذا)... هنا احتمالات الـ **random variable** بتاعي (اللي هو الطقس weather) من قيم ثابتة او **discrete**

$$X = x \in \{ \text{Sunny}, \text{Cloudy}, \text{Rainy}, \dots \}$$

نسجل بقى الاحتمالات دي لكل يوم بيعدى (هختصر برضه الطقس بحروف زي S و R، والوقت طبعاً هكتبه بت) يعني مثلاً يوم ممكن يطلع مشمس اللي بعديه ممكن يطلع غائم وبعديه ممكن يبقى مشمس وهكذا:

t	1	2	3	4	...
X = x	S	C	S	R	...

دلوقي بقى كل time موجود بقى مربوط بوحدة من احتماليات الـ random variable ...weather ... ومبروك انت كدة عملت ابسط stochastic process ممكن تخيلها! نحط بقى تعريف ثابت للـ stochastic process (او ليه اسم random process برضه):

- A stochastic process (SP) is a collection of random variables indexed with time.

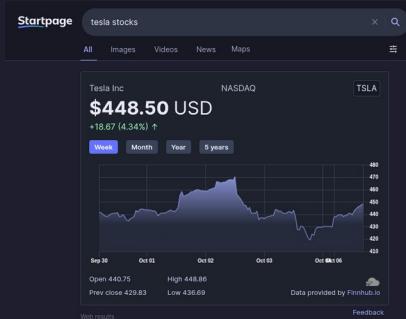
معني ان اي stochastic process هي مجموعة random variables متأشرة (او مخطوطتها index) بالوقت، كل واحد من الـ random variables مربوط بالوقت بتناعها في الـ process (زي ان تاني يوم في مثال الطقس ليه احتمال بقى غائم وكدة). مهم اوي عشان لما اجي اشرح حاجات ياما بعدين تبقي معايا في الصورة: احنا بنسمي كل الحالات اللي بيبقى فيها الـ random variables دي باسم الحالات او states، او وضع الـ process في الوقت الفلاني (برضه في مثال الطقس ان state او حالة اليوم الثالث تبقي مشمسة او sunny).

3. انواع وتعريفات الـ stochastic processes نفسها:

في مثال الطقس اللي فات قولت قبل ما انا اعمله ان الـ states بتناعته من قيم ثابتة او discrete. الوقت برضه في المثال لو انت مخدتش بالك منه فهو هو كمان عشان كل يوم ثابت بحطله ريكورد واحد... وبكدة بقى عندنا اول نوع من الـ processes وهو الـ discrete-time and discrete-space (بنختصره بـ DT-DS).

طب لو الوقت بقى continuous؟ (يعني

بقيس الحالة بتناعت حاجة معينة بالثانية؟) ممكن برضه وفيه مثال على ده هو الـ uptime بتناع سيسنتم معين زي states الكلية كدة... هنا الـ بتاعتنا (في الـ state space) بتبقى normal (فاضي) و high (عادي) و low (ضغط عالي او مشغول) يعني discrete برضه، والوقت بيتقاس بالثانية او حتى بالمللي ثانية اللي كل حاجة شغالة فيها يعني continuous ... ده كدة ثاني نوع وهو الـ continuous-time and discrete-space (اختصاره CT-DS).



طب لو الاتنين بقوا **continuous**? ده مثالها سهل ومشهور وهو سوق الأسهم او ال stock market ...stock market هنا بيقي سعر السهم بالدولار وبيبقى ال state space متغير لدرجة ان الدقة فيه بالسنت، وال time متغير برضه بالثانية... يعني كدة معانا تالت نوع وهو **continuous-time and continuous-space** ال اختصاره **(CT-CS)**.

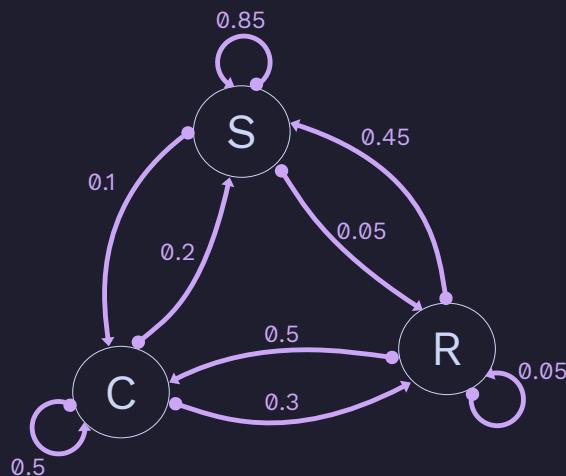
فاضلنا كدة نوع رابع وهضريلك مثال رابع عليه... لو خدنا ربح شركة او بزنس معين كل شهر احنا ممكن نعتبر الربح ده (او ال state space اللي ممكن الربح ده بيقي فيه) متغير، وفي نفس الوقت ال time بتاعك اللي بتقيس بيه بالشهر ودول ثابتين... وده رابع نوع **(DT-CS) او discrete-time and continuous-space**.

نراجع بقى عالأربع انواع ورا بعض:

- Discrete-time and discrete-space (DT-DS). (مثال الطقس)
- Continuous-time and discrete-space (CT-DS). (مثال سيستم الكلية)
- Continuous-time and continuous-space (CT-CS). (مثال سوق الأسهم)
- Discrete-time and continuous-space (DT-CS). (مثال ربح الشركة)

4. ال **Markov chains** وعماليهم:

بسمع حد بيسأل دلوقتي طب الاحتمالات غابت وهرجع امتى؟ ساعتها هقولك هنرجع تاني لمثال الطقس اللي في الأول خالص وساعتها بدل ما هنعواز احتمال كل يوم لأ احنا عايزين احتمال ان حالة طقس تتغير لحالة طقس تانية (يعني مثلًا اعرف ان احتمالية ان الطقس يتغير من C ل S ب 0.2، او احتمالية ان ال R تفضل على حالها للليوم اللي بعده ب 0.05 وهكذا)... انا ممكن ارسم الانتقالات او ال transitions دي نفسها في رسمة بسيطة:



وبكدة اعرف في لحظة لو حالة الطقس في يوم معين S فاحتمال انها تبقى R اليوم اللي بعده ب 0.05. الرسمة دي بنسميها ال one-step transition diagram عشان بتديينا كل احتمال اني انقل خطوة واحدة لقدمام من state ل state تانية في رسمة زي دي.

انا ممكن برضه اترجم الـ **matrix** اللي زى دى لـ **diagrams** هتكمel معانا حبة حلولين
لقدام (وھسمى الـ **matrix** دى الـ **(one-step transition matrix)**)

$$P = \begin{bmatrix} 0.85 & 0.1 & 0.05 \\ 0.2 & 0.5 & 0.3 \\ 0.45 & 0.5 & 0.05 \end{bmatrix}$$

طبعاً مش هتفهم حاجة دلوقتي عشان متعرفش كل رقم بتاع انهي transition في الجدول اللي فوق بالظبط... خليني اساعدك شوية:

$$P = \begin{array}{ccc} & S & C & R \\ \begin{matrix} S \\ C \\ R \end{matrix} & \begin{bmatrix} 0.85 & 0.1 & 0.05 \\ 0.2 & 0.5 & 0.3 \\ 0.45 & 0.5 & 0.05 \end{bmatrix} \end{array}$$

دلوقتي كل صف اعتبره "من" وكل عمود اعتبره "إلي"، يعني مثلاً لو انا عايز اروح من C لـ S ببقي هشوف الرقم اللي في الصف C واللي في العمود S (وهيبيقي اسمه P_{CS} ، اول حرف طبعاً ببقي الـ "من" والتاني ببقي الـ "إلي"):

$$P = \begin{array}{ccc} & S & C & R \\ \begin{matrix} S \\ C \\ R \end{matrix} & \begin{bmatrix} 0.85 & 0.1 & 0.05 \\ 0.2 & 0.5 & 0.3 \\ 0.45 & 0.5 & 0.05 \end{bmatrix} \end{array} \rightarrow P_{CS} = P(X_1 = S \mid X_0 = C) = 0.2$$

كمان مرة: لو عايز اروح من الـ R لنفسها (P_{RR}) هاخد الرقم اللي تحت عالشمال:

$$P = \begin{array}{ccc} & S & C & R \\ \begin{matrix} S \\ C \\ R \end{matrix} & \begin{bmatrix} 0.85 & 0.1 & 0.05 \\ 0.2 & 0.5 & 0.3 \\ 0.45 & 0.5 & 0.05 \end{bmatrix} \end{array} \rightarrow P_{RR} = P(X_1 = R \mid X_0 = R) = 0.05$$

اللي احنا كنا بنوصفه ده عموماً مثال على Markov chain ... وتعريفه ببساطة انه discrete-time and discrete-space stochastic process (DT-DS) ومتعزّف بإحتماليات ال transitions بقاعدته بس. ده يجيينا لخاصية مهمة ليه وهي كالتالي:

- Next step only depends on the **present state**, not on the past.

يعني ان اي خطوة جاية عايز اجيب احتمالها بجيها على اساس ال state اللي انا واقف فيها دلوقتي وملыш دعوه بأي خطوة قبلها... يعني مثلاً انت عايز تجيب احتمال ان ال state الجاية تبقي S بمعلومية ان ال state اللي قبلها على طول C واللي قبل اللي قبلها R وهكذا:

$$P(X_t=S \mid X_{t-1}=C, X_{t-2}=R, \dots)$$

ال اللي انا عايز اجيدها دي t، بقى طبيعي اللي انا واقف عندها دلوقتي تبقي t-1 واللي قبلهم اصغر منهم زي t-2 وهكذا... الخاصية بتاعتنا بتقولك لأنك ممكن تلغى كل اللي قبل ال present state عادي (خد بالك برضه انا رايح من انهي state وهوصل انهي state):

$$\begin{aligned} P(X_t=S \mid X_{t-1}=C, \cancel{X_{t-2}=R}, \dots) \\ = P(X_t=S \mid X_{t-1}=C) = P_{CS} \end{aligned}$$

5. كام خاصية وكم معلومة مهمة في ال one-step transition matrices في ال one-step transition matrix اللي فصلناها نركز فيها شوية:

$$P = \begin{bmatrix} 0.85 & 0.1 & 0.05 \\ 0.2 & 0.5 & 0.3 \\ 0.45 & 0.5 & 0.05 \end{bmatrix}$$

هظبطهالك شوية وهقولك على اسم كل واحد من المتغيرات دي في P :

$$P = \begin{bmatrix} P_{SS} & P_{SC} & P_{SR} \\ P_{CS} & P_{CC} & P_{CR} \\ P_{RS} & P_{RC} & P_{RR} \end{bmatrix}$$

هنا بقى انا عايز الفت نظرك لمصطلح مهم اسمه **state space** (يعني فضاء الحالات **S**)... وهو كل الحالات الممكنة اللي ممكن اوصلها... يعني في ال transition matrix اللي فاتت ال state space بتاعتي هتنكتب كدة:

$$S = \{ S, C, R \}$$

في **Markov chain** تانية خالص ممكن يكون كل الحالات اللي فيها او ال state space بتتنكتب كدة:

$$S = \{ 1, 2, 3 \}$$

ساعتها ال one-step transition matrix بتاعتنا هتبقي كدة:

$$P = \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}$$

ومن هنا تقدر تحط كل P في ال matrix بкам ساعتها... المهم تعرف لو قولتلك مثلاً P_{32} او P_{11} (او حتى P_{SR} في مثال الطقس اللي قبليه) تفهم بتكلم علي انهي حته في ال matrix كوييس...

طب ايوة فين جزء الماث والخصائص في الحوار؟ طب ركز معايا.
اول حاجة واضحة فيها ان دي matrix احتمالات... يعني كل رقم بلا استثناء اقل من او يساوي 1)... بدويهيات يعني:

$$0 \leq P_{ij} \leq 1$$

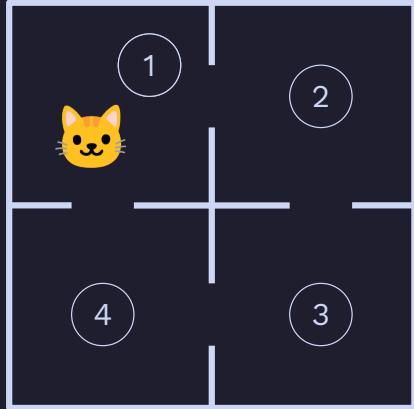
عالاقل خلبيتك تاخد بالك من الا وآلز اللي تحت (الا الا "من" يعني الصف اللي انت فيه والز الا "إلي" يعني العمود اللي انت فيه برضه).
اللي مش بدويهبي المرادي ان مجموع ال elements في كل صف (او بمعنى اصح كل probabilities اللي طالعين من state) بيتساواوا واحد:

$$\sum_j P_{ij} = 1$$

ركز كدة معايا (عشان مش هرزعلك او وز وهخلع)... ا LZ دي اللي بغير فيها واصلاً في مكان الا "إلي" زي ما شرحتلك فوق وبثبت الا اللي في مكان الا "من".
عارف ايه دي شبه ايه برضه في ال one-step transition diagram زي اللي فوق؟ خد اي دائرة (او state) واجمع كل الاسهم اللي طالعين منها.

Lec2: Initial Distributions and Multi-step Transitions

1. مسألة كيوت بس مهمة:



Q: Cat must move to an adjacent room every one time. For the following figure, position represents its states. Is this process a Markov chain? If yes, find P.

- عندك قطة لازم تتحرك لغرفة مجاورة للي هي فيها كل مرة. زي ما الشكل بيقولك، مكان القطة بيمثل حالتها. هي الـ process دى Markov chain؟ لو اه هاتلي الـ P بتاعتتها.

الحل:

هنا انا بشكل كبير معايا رسمة متحدة وقايili ان مكانها متعدد في الرسمة... ساعتها هشوف هي القطة فين دلوقتي وتقدر تتحرك فين بعد كدة:

القطة عند 1 (ده ال initial position او المكان المبدئي بتاعتها)... وقالك ان هي must move to an adjacent room every one time كل مرة... يعني من عندها ممكن تروح ل 2 او 4 (وهيبيقي احتمال انها تروح للأوضة دي او دي متساويين يعني بـ 0.5 طالما مقالش اي حاجة عن الاحتمالات) بس مينفعش انها تفضل في مكانها في 1 او تروح ل 3... نفس الكلام لو القطة في 4 ينفع بس تروح ل 1 او 3 (برضه الاحتمالات متساوية وبـ 0.5) بس متفضلش في 4 او تروح ل 2. القطة ممكن تروح كل الأوض فممكן اقول ان ال state space او الحالات بتاعتي كدة:

$$S = \{1, 2, 3, 4\}$$

كدة بعد ما فهمنا الرسمة خلينا نقوله علي الحل واحدة واحدة...

- Is this process a Markov chain?

- Based on the figure, the past doesn't affect the future state, only the cat's position (the present state) does. Also, the probability doesn't change with time. Hence, a Markov chain.

- هنا الماضي مبيأثرش علي القطة هتروج فين. مكان القطة دلوقتي هو بس اللي بيأثر. غير كدة مفيش احتمالات بتتغير مع الوقت فممكן نقول انها Markov chain عادي.

- Find P.

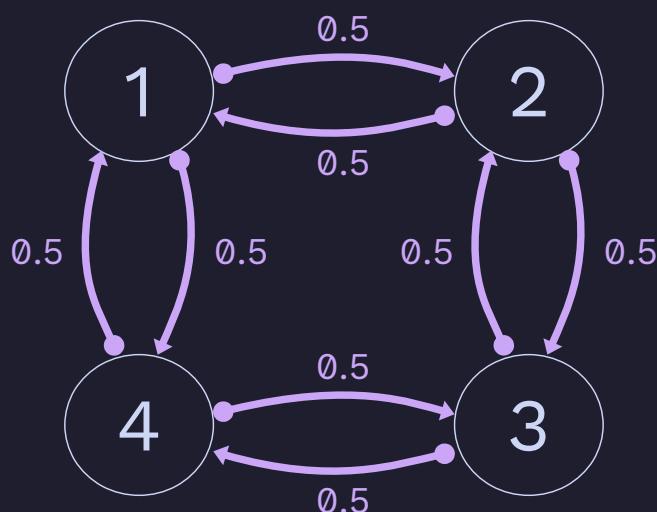
هنا انت عايز تجيبي ال one-step transition matrix بـتاعتك عادي (واحنا من شوية لسة مفصلين احتمالات انك هتروج لأنهي state من انهي state بالضبط)... فال مهم دى ال P بـتاعتك:

$$P = \begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{bmatrix}$$

واطن هتووضح اكتر لو حطيتلك ال states عليها زي المرة اللي فاتت:

$$P = \begin{bmatrix} & 1 & 2 & 3 & 4 \\ 1 & 0 & 0.5 & 0 & 0.5 \\ 2 & 0.5 & 0 & 0.5 & 0 \\ 3 & 0 & 0.5 & 0 & 0.5 \\ 4 & 0.5 & 0 & 0.5 & 0 \end{bmatrix}$$

كدة بـأينة اكتر بـكتير لو انا مثلاً واقف عند 1 هيقي احتمالية اني اروح لـ 2 او 4 بـ 0.5، واحتمالية اني اروح لـ 3 او افضل واقف عن 1 بـ 0 (عشان مينفعش اصلاً).
بالمرة بـرضه خدوا انشالله ما حد حوش:



2. يعني ايه initial distribution؟

ال initial distribution states (او التوزيعة المبدئية) ده لامملک فيه كل احتمالات ال states قبل ما تبدأ حتى اول خطوة... بمعنى؟

ارجع كدة لمثال القطة... هو قايلك صريحة ان القطة عند state رقم 1 واحنا اشتغلنا علي ده للآخر... يعني كدة احتمال ان القطة تبدأ من state رقم 1 بـ 1 واحتمال انها تبدأ بـ state رقم 2 او 3 او 4 بـ 0... هندي بقى احتمالات ال states عند البداية بـ π^0 (او π^0):

$$\pi^0 = \begin{bmatrix} \pi_1^0 = P(X_0=1) \\ \pi_2^0 = P(X_0=2) \\ \pi_3^0 = P(X_0=3) \\ \pi_4^0 = P(X_0=4) \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

اه صح انا راصدلك ال vector كله بالطول مبدئياً للتوضيح مش اكتر هو في العادي بالعرض.

خدت بالك انا برمز لـ vector كله (او ال initial distribution) بـ π^0 ... ولو عايز ارمز لـ state معينة من ال initial distribution زي اول state برمزله بـ π_1^0 او زي تاني state فبرمزله بـ π_2^0 وهكذا.

طب عدي تايم واحد او خطوة واحدة، فطبععي الاقي توزيعة لـ states بعد الخطوة دي واسمها position distribution after 1 step (او π^1):

$$\pi^1 = \begin{bmatrix} \pi_1^1 = P(X_1=1) \\ \pi_2^1 = P(X_1=2) \\ \pi_3^1 = P(X_1=3) \\ \pi_4^1 = P(X_1=4) \end{bmatrix} = \begin{bmatrix} 0 \\ 0.5 \\ 0 \\ 0.5 \end{bmatrix}$$

الارقام دي موجودة عشان المثال اللي كنا فيه مش اكتر... بس زي اي حاجة ماث اكيد اكيد فيه طريقة او معادلة ثابتة اجيب كل ده بيها... وهنا انا جايلك في الصفحة الجاية بـ ثبات صغنتوت:

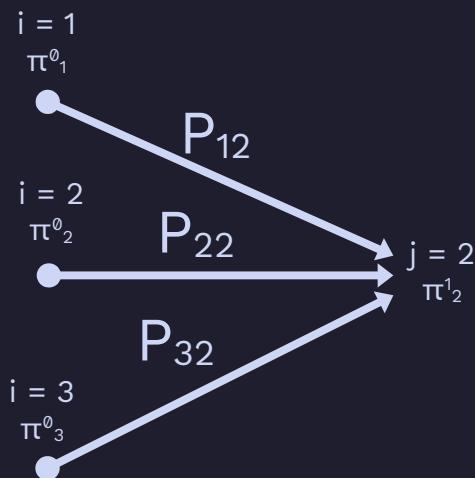
time = t
state = i

P_{ij}

time = t+1
state = j

عموماً لما بروح من state للثانية فيه الاحتمالية
بتاعت ال one-step transition (اللي بتتجاب من ال P عادي، وساعتها انا معايا احتمالية
ال transition ده لوحده اللي هو π_j). متفقين؟
طب لو جيت وحطيت معها احتمال اني ابقي في state معين قبل ما حتي اشوف هو
هيروح لأنهي state قبليها؟

تعالي ركز معايا في الحالة دي: لو معانا $S = \{1, 2, 3\}$ (كمان مرة دي ال state space)
وعايز اجيب احتمال اني بعد اول خطوة هروح ل state رقم 2 مثلاً (وركز احنا مع "إلي"
مش "من" المرادي) بس في نفس الوقت فيه احتمال initial اني ابقي عند انهي state
الأول... اللي هو ال π^0 برافو عليك (وهنا هفصصها لك لكل state من التلاتة):



كدة بقى انا وصلت ل state رقم 2 وبقى فيه احتمال جديد هحسبه اني بقىت عند
ال state دي (اللي هو π^1_2) وده بقى بيتحسب اني بضرب كل π في ال P بتاعتتها
وبجمعهم مع بعض (زي ال dot product كدة):

$$\pi^1_2 = \pi^0 P_{i2} = \pi^0_1 P_{12} + \pi^0_2 P_{22} + \pi^0_3 P_{32}$$

بس احنا مش عايزين π^1 بس... لا احنا عايزين π^1 بتاع π^1 كله... وساعتها
هحتاج ال matrix بتاعت ال P كلها مش عمود ال P_{i2} بس... يعني بمعنى اصح هضرب
:matrix في vector

$$\pi^1 = \begin{bmatrix} \pi^1_1 & \pi^1_2 & \pi^1_3 \end{bmatrix}$$

$$= \pi^0 P = \begin{bmatrix} \pi^0_1 & \pi^0_2 & \pi^0_3 \end{bmatrix} \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}$$

وبالمرة هعملك علي $\pi^0 P$ من قلب ضرب الاثنين في بعض:

$$\begin{aligned}\pi^1 &= \begin{bmatrix} \pi_1^1 & \pi_2^1 & \pi_3^1 \end{bmatrix} \\ \pi^0 P &= \begin{bmatrix} \pi_1^0 & \pi_2^0 & \pi_3^0 \end{bmatrix} \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}\end{aligned}$$

3. نطينا من ال **multi-step** لل **one-step**

هستفيدي تاني من خاصية ال Markov chain الأجمل ان كل step ملهاش دعوة باللي قبليها... فممكן اني ابدل ال π^0 من المعادلة ب π^1 عشان اجيب ال π^2 ، ومن ال π^2 ممك انط لل π^3 وهكذا (من غير ما اغير ال P تبقي هي هي عادي).

طب سؤال خبيث: لو جربت وعوضت بمعادلة ال π^1 في مكان معادلة ال π^2 ? ايه اللي هيحصل؟

$$\pi^2 = (\pi^0 P) P = \pi^0 P^2$$

يعني انا مثلًا ممك اجيب احتمالات خطوتين في بعض على طول من غير ال π^1 ? حصل وال P^2 دي تعتبر ال **two-step transition matrix**. ولو عايز اجيب ال **three-step transition matrix** وماليه انا موافق اضرب الطرفين في P مرة كمان:

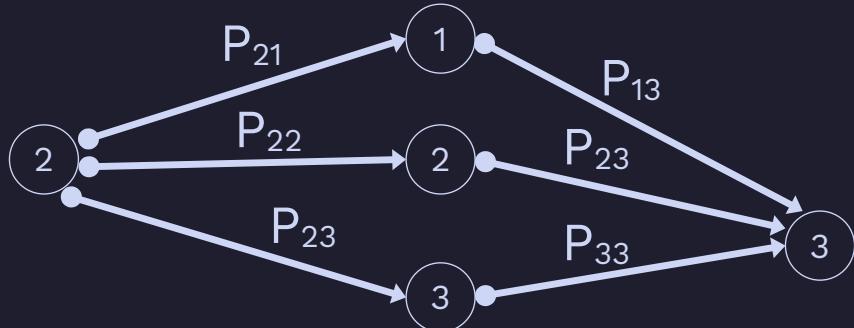
$$\pi^3 = (\pi^0 P^2) P = \pi^0 P^3$$

وبشكل عام اي π^n ممك تتجاب من ال π^0 وال P^n (سميها ال **n-step transition matrix** بالمرة وخليلك ناصح):

$$\pi^n = \pi^0 P^n$$

طب ماشي ال P اما نضربها في نفسها ونحطلها باور وفهمناها... بس يعني ايه حاجة زي P^2 ? واجيب احتمالات اني اروح من state للثانية في خطوتين ازاي؟ ساعتها هنعدل على الاثبتات اللي فات ونشرح منه...

هجيبلك نفس مثال الاسهم (برضه $S=\{1,2,3\}$) واني اروح من state للثانية... بس المرادي انا معايا خطوتين وبالخطوتين لازم اروح من state رقم 2 لـ state رقم 3 (عادي ان الخطوة افضل بيها عند نفس الـ state كدة)... فممك اروح لـ 1 بعدين 3، ومممك اروح لـ 3 او اول خطوة وبعدين افضل عند 3 الثانية:



فال مهم برضه بدل ما يبقي عندي احتمالات الخطوة والـ initial بقى عندي احتمال خطوتين في بعض... دلوقتي مطلوب احسب مني الاحتمال الجديد (اللي اسمه P^2_{23})، وهحسبه بنفس طريقة الـ dot product هضرب كل اتنين P بعد بعض وهجمعهم:

$$P^2_{23} = P(X_2=3 \mid X_0=2) = P_{2j} P_{i3} = P_{21} P_{13} + P_{22} P_{23} + P_{23} P_{33}$$

برضه احنا مش عايزين الـ P^2_{23} وخلاص احنا عايزين الـ P^2 مرة واحدة... وبكدة مشحتاج اقولك انك هتضرب الـ P في نفسها:

$$P^2 = \begin{bmatrix} P_{11}^2 & P_{12}^2 & P_{13}^2 \\ P_{21}^2 & P_{22}^2 & P_{23}^2 \\ P_{31}^2 & P_{32}^2 & P_{33}^2 \end{bmatrix} = PP = \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix} \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}$$

كمان مرة هعملنك على P^2_{23} من قلب ضرب الـ matrices في بعض (زي ما انت عارف اول رقم ده الصف وتاني رقم ده العمود... فهنا هضرب تاني صف في تالت عمود):

$$P^2 = \begin{bmatrix} P_{11}^2 & P_{12}^2 & P_{13}^2 \\ P_{21}^2 & P_{22}^2 & \mathbf{P}_{23}^2 \\ P_{31}^2 & P_{32}^2 & P_{33}^2 \end{bmatrix} = \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ \mathbf{P}_{21} & \mathbf{P}_{22} & \mathbf{P}_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix} \begin{bmatrix} P_{11} & P_{12} & \mathbf{P}_{13} \\ P_{21} & P_{22} & \mathbf{P}_{23} \\ P_{31} & P_{32} & \mathbf{P}_{33} \end{bmatrix}$$

ولو لسبب ما تحتاج P^3 عينيا انت تؤمر... انت كدة تحتاج تضرب الصف الثاني بتاع ال P في كل العواميد بتاعت ال P الأول عشان تطلع صف جديد من ال P^2 , بعدين تضرب الصف الجديد من P^2 من الأول في العمود الثالث:

$$P^3 = \begin{bmatrix} P_{11}^3 & P_{12}^3 & P_{13}^3 \\ P_{21}^3 & P_{22}^3 & P_{23}^3 \\ P_{31}^3 & P_{32}^3 & P_{33}^3 \end{bmatrix} = P^2 P = \begin{bmatrix} P_{11}^2 & P_{12}^2 & P_{13}^2 \\ P_{21}^2 & P_{22}^2 & P_{23}^2 \\ P_{31}^2 & P_{32}^2 & P_{33}^2 \end{bmatrix} \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}$$

بلاش بالله عليك تسألي علي P^4 عشان هفاجئك واقولك انك لازم تطلع P كلها رقم رقم عشانها الأول. -_-

4. احتمالات ال intersection

نرجع نفترك انت لما كنت بتجيب احتمال خطوة معينة من state للثانية (نقول مثلاً من 2 لـ 3 كالعادة) انت كنت بتجيبيها بال conditional عادي:

$$P(X_1=2 \mid X_0=1) = P_{12}$$

هنا انا اللي مهمني بس فرق التايم بين الاثنين (كنت عند تايم 0 او ال initial في state رقم 1، وكنت عند تايم 1 في state رقم 2)... يعني انا مهممنيش في ال conditional لو زودت على التايم براحتي وحайд هنا وهناك (هي كدة كدة خطوة واحدة اللي بعملها):

$$P(X_9=2 \mid X_8=1) = P_{12}$$

طب لو انا عايز بقى الاحتمالية ان مثلاً عند تايم 1 بالضبط ابقي في state رقم 2 ومعاها عند تايم 2 بالضبط ابقي في state رقم 3؟ هتلجأ ساعتها للتقطاع او ال intersection

$$P(X_2=3, X_1=2)$$

علامة الكواما ، اللي في النص دي (ممك اسميهها and عادي) زيها زي ال \cap اللي نعرفها كلنا عادي... و ساعتها نفترك قانون نقصص ده بيء من ايام البروب 1:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \rightarrow P(A \cap B) = P(A|B)P(B)$$

اللي هو من اي intersection لازم تطلع منها ال conditional (احتمال الخطوة نفسها) وكمان احتمال ال B نفسه.

عندنا في الستووكاستيك بقى احنا بنطلع التايم الأصغر برا وبنشوف احتمالية ال state $P(X_2=3, X_1=2)$ (وده ال present واللي عرفنا انه موجود من جوا ال π^1):

$$P(X_2=3, X_1=2) = P(X_2=3 \mid X_1=2) P(X_1=2) = P_{23} \pi_2^1$$

طب لو اكتر من intersection؟ غير انى ممكن افكم مرد على مرد زى تانى سطر (وامسك كل اللي بعد اول probability في and لوحده) بس عايز اقولك انى ممكن اختصر واجيب الناتج النهائي في حركة واحدة هعملها في خامس سطر بس تفهمها: هجيب ال conditional بين كل اتنين ورا بعض وفي الآخر هجيب احتمالية اللي بأقل تايم لوحده... اهم حاجة بس الترتيب وحياتك:

$$\begin{aligned} & P(X_4=1, X_3=1, X_2=3, X_1=2) \\ &= P(X_4=1 \mid X_3=1, \cancel{X_2=3}, \cancel{X_1=2}) P(X_3=1, X_2=3, X_1=2) \\ &= P(X_4=1 \mid X_3=1) P(X_3=1 \mid X_2=3, \cancel{X_1=2}) P(X_2=3, X_1=2) \\ & \quad = \dots \\ &= P(X_4=1 \mid X_3=1) P(X_3=1 \mid X_2=3) P(X_2=3 \mid X_1=2) P(X_1=2) \\ & \quad = P_{11} P_{31} P_{23} \pi_2^1 \end{aligned}$$

طب لو ميكس بين الاثنين؟ انت عارف من Lec1 اول ميكس فيهم ان انا لو جالي وكذا state من الماضي مع بعض باخد اقرب حاجة لل future (ممكنا نخش على ال multi-step ساعتها المهم عندي هيبيقي اعلى واقرب تايم)... يعني مثلاً لو اديتك مثال زى ده:

$$P(X_7=1 \mid X_2=3, X_6=2, X_5=1, X_4=3)$$

طب ما انا لو رتببت التايم من الكبير للصغير (وده لازم اعمله دائمًا) ممكن اختصر كل اللي بعد اكير تايم:

$$\begin{aligned} & P(X_7=1 \mid X_6=2, \cancel{X_5=3}, \cancel{X_4=1}, \cancel{X_3=3}) \\ & P(X_7=1 \mid X_6=2) = P_{21} \end{aligned}$$

تاني ميكس بقى لو جبتك ال intersection في الأول فهتفك كل واحد فيهم واحدة واحدة لحد ما توصل ل conditional ممكن تلغى الكذا intersection اللي بعديه براحتك... تعالى مثلًا:

$$P(X_6=2, X_7=1 \mid X_3=1, X_5=3)$$

ممك تجرب تفكها براحتك عادي قبل ما اقولك الحل... المهم بس قبل ما تفك ترتب (ولما تفك ممك تعتبر كلل اللي بعد علامة ال intersection عادي)...

الحل:

عايز اقولك ان فيه حركة جديدة خبيثة هعملها: انا لو لقيت اتنين conditional ورا بعض طبعاً عشان انا في Markov chain ممك اكنسل ال **conditional** الثاني عادي:

$$\begin{aligned} & P(X_7=1, X_6=2 \mid X_5=3, X_3=1) \\ = & P(X_7=1 \mid X_6=2, \cancel{X_5=3}, \cancel{X_3=1}) P(X_6=2 \mid X_5=3, \cancel{X_3=1}) \\ = & P(X_7=1 \mid X_6=2) P(X_6=2 \mid X_5=3) = P_{21} P_{32} \end{aligned}$$

5. احتمالات ال **multi-step**:

طب بدل ال **conditional** العادي ابو خطوة واحدة ممك عادي اخليلك الفرق بين التaim في الاتنين states اكتر من واحد... اتنين او ثلاثة مثلًا:

$$P(X_2=3 \mid X_0=1) = P_{13}^2$$

انت اكيد شوفت انا ممك اجيها من اي باور لل **P** من غير اي مشاكل (زي P^2 في المثال هنا)... فمثلاً لو فيه مسألة طلب مني فيها بعد خطوتين او ثلاثة اجيب احتمالية انه بقى في ال state كذا فالطريقة دي اللي هتشتغل بيها.
واكيد نفس الموضوع ممك اطبقه بالمللي على ال intersections والميكسات وكل اللي شرحناه الصفحتين اللي فاتوا عادي:

$$P(X_3=1, X_1=2)$$

فده مثلًا هعرف افكه في ثانيتها:

$$= P(X_3=1 \mid X_1=2) P(X_1=2) = P_{21}^2 \pi_2^1$$

تخش على كام مثال هي نطبق فيه على كل ده؟

6. مسألة التossing

Q: Four players A, B, C, D are tossing a ball among themselves.

- If A has the ball, they toss it to B with probability $\frac{1}{2}$ and to C or D with equal probability.
- If B has the ball, they pass it to either A or D with equal probability.
- If C has the ball, they pass it to A with probability twice that of passing it to D.
- If D has the ball, they always toss it to C.

The ball is initially with player A.

a) Construct the transition matrix.

b) What is the probability the ball moves from player B to player D?

c) What is the probability that after two tosses it is with player C?

d) What is the probability that C will have the ball after the first toss and A will have it after the third toss?

بإختصار هو مديك اربع لاعبين بيرموا الكورة لبعض (وكل واحد بيرمي الكورة بشرط معينة)، فعايز منك الـ transition matrix (الـ P) وتططلع منها كام احتمال كمان.

الحل:

إنت كدة كدة في الأول هتبص علي كل حد فيهم هو بيرمي الكورة فين بالظبط وهتملي الـ P علي اساس كل ده:

- اول لاعب A بيرمي الكورة لـ B باحتمال $\frac{1}{2}$ ولـ C أو D باحتمالات متساوية with equal probability (يعني هيennis معاهم النص الباقي فاحتمال كل واحد فيهم $\frac{1}{4}$).
- تاني لاعب B بيرمي الكورة لـ A ولـ D باحتمالات متساوية (هيennis معاهم الاحتمال كله فاحتمال كل واحد فيهم $\frac{1}{2}$).

- تالت لاعب C بيرمي الكورة لـ A بس بضعف إحتمال اللي بيرمي له D (هي بديهية شوية ان الاحتمال هييقي $\frac{2}{3}$ لـ A و $\frac{1}{3}$ لـ D بس لو عايز تشتغلها $1 = 2x + x$ مفيش مشاكل عادي).

- رابع لاعب D بيدي الكورة دائمًا لـ C فمش محتاج اقول ان الاحتمال بـ 1. فيه كمان حاجة عطاها لك **given** وهي ان الكورة بتبدأ مع A دائمًا (ودي هنحتاجها بعدين مش دلوقتي).

ساعتها انت لما تيجي تعمل ال transition matrix كل اللي قايلك عليه في كل صف بالظبط (وھتفهم کدة ان محدش هيخلي الكورة مع نفسه في اي وقت فھتصفر ال diagonal کله علي طول).

a) Construct the transition matrix.

$$P = \begin{bmatrix} 0 & 1/2 & 1/4 & 1/4 \\ 1/2 & 0 & 0 & 1/2 \\ 2/3 & 0 & 0 & 1/3 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

b) What is the probability the ball moves from player B to player D?

طبعا هنا هو عايز P_{BD} واللي ساعتها في تاني صف ورابع عمود و($=\frac{1}{2}$).

$$P(X_1=D \mid X_0=B) = P_{BD} = 1/2$$

c) What is the probability that after two tosses it is with player C?

هنا عايز P^2_{AC} ودي هجيبيها من dot product صف ال A مع عمود ال C في ال:

$$P^2 = \begin{bmatrix} 0 & 1/2 & 1/4 & 1/4 \\ 1/2 & 0 & 0 & 1/2 \\ 2/3 & 0 & 0 & 1/3 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1/2 & 1/4 & 1/4 \\ 1/2 & 0 & 0 & 1/2 \\ 2/3 & 0 & 0 & 1/3 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$\begin{aligned} P(X_2=C \mid X_0=A) &= P_{AC}^2 \\ &= 0(1/4) + (1/2)(0) + (1/4)(0) + (1/4)(1) = 1/4 \end{aligned}$$

d) What is the probability that C will have the ball after the first toss and A will have it after the third toss?

بيقولك دوغرى هو عايز ان اول تايم لازم ال state بتاعه C وثالث تايم لازم ال state بتاعه A ... هنا مش هعرف اجيب P مباشرة عشان هو كدة عايز مني intersection اصلاً مش conditional بس:

$$P(X_3 = A, X_1 = C)$$

ساعتها هفصصها ببساطة:

$$= P(X_3 = A \mid X_1 = C) P(X_1 = C) = P_{CA}^2 \pi_C^1$$

بس ثانية...انا معيش π^1 ولا π^0 حتى... ساعتها هقولك استخدم ال given اللي قولتلك خليه بعدين ان الكورة هتبدأ مع A، يعني معنى كدة ان ال π^0 على بعضها هتبقي بـ [1,0,0,0]، يدوبك هتجيب ال P_{CA}^2 وبعدين ال π_C^1 وبكدة مبروك عليك الناتج:

$$\pi^1 = \pi^0 P = \begin{bmatrix} 1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1/2 & 1/4 & 1/4 \\ 1/2 & 0 & 0 & 1/2 \\ 2/3 & 0 & 0 & 1/3 \\ 0 & 0 & 1 & 0 \end{bmatrix} \rightarrow \pi_C^1 = 1(1/4) = 1/4$$

$$P^2 = \begin{bmatrix} 0 & 1/2 & 1/4 & 1/4 \\ 1/2 & 0 & 0 & 1/2 \\ 2/3 & 0 & 0 & 1/3 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1/2 & 1/4 & 1/4 \\ 1/2 & 0 & 0 & 1/2 \\ 2/3 & 0 & 0 & 1/3 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

$$\rightarrow P_{CA}^2 = (2/3)0 + (0)(1/2) + 0(2/3) + (1/3)(0) = 0$$

$$P(X_3 = A, X_1 = C) = P_{CA}^2 \pi_C^1 = 0(1/4) = 0$$

صفر؟ هو انا كدة عملت حاجة غلط؟ لأ عادي لو طلع الناتج في اي مسألة بـ 0 مفيش مشاكل... بيبني وبينك بالعقل السيناريyo ده مستحيل عشان يا اما C هيوودي الكورة لـ A بعدين لازم تفلت منه، يا اما هيووديها لـ D ولازم ترجع لـ C تاني، فأنا عارف ان P_{CA}^2 بصفر بس اديك انت جبتها بالمات باللي بنحل بيها (:

7. مسألة الـ counting :counting

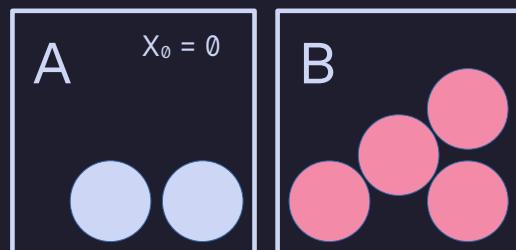
Q: We have two boxes: box A contains 2 white balls, and box B contains 4 red balls. At each time we select a ball from box A and interchange it with box B. $X_n = \#$ of red balls in A.

Find:

- P
- π^0
- π^1
- $P(X_1 = 1, X_2 = 1, X_3 = 2)$

الحل:

بص خلينا نرسمها... انت الأول عندك صندوق A فيه كورتين بيض، وصندوق تاني اسمه B عندك فيه اربع كور حمر. هو بيقولك انا هاخد كورة من A وهبدلها مع واحدة من B عمياني (يعني كدة لو تركز انا في الصندوق A ممكن يبقى عندي يا صفر كور حمرا، يا كورة واحدة حمرا، يا كورتين حمر).



بسم الله الرحمن الرحيم كدة الـ state space $S=\{0,1,2\}$ بتاعتي اللي هي عدد الكور الحمرا في A، والـ initial بتاعي 0 (عشان مديلك في راس السؤال given ان A كلها بدأت بكورتين بيض)... كدة $\pi^0 = [1,0,0]$ اول مطلوب وراح لحاله.

$$S=\{0,1,2\}, \quad \pi^0 = [1 \ 0 \ 0]$$

طب دلوقتي من الـ initial انا روحت عملت اول تبديلة (يعني بدلت كورة من A مع كورة من B)... مش كدة كدة غصب انا هحط كورة حمرا في A وهودي كورة بيضا في B؟ حصل (روحت من state رقم 0 يعني مفيش كورة حمرا لـ state رقم 1 يعني فيه كورة واحدة حمرا) وكدة انا جبت 1 ($P_{01} = 1$) (وبرضه هكون جبت بالفهلوة $[0,1,0] = \pi^1$ بس مش عايز امشي حاليا بالفهلوة دلوقتي خلينا دوغرى).

هنجيب برضه كذا احتمال محتاجينه منك... تركيزك بقى وانت بتفهمهم:

- انا ببدل كورة واحدة بس كل مرة (يعني لازم عشان اروح من 0 ل 2 او العكس لازم اعدي علي state رقم 1 الأول)، فكدة استحالة اروح من state 0 ل state 2 او العكس ($P_{02} = 0$, $P_{20} = 0$).

- في صندوق A لو كله كور بيضا (رقم 0) مش غصب الخطوة الجاية هحطله كورة حمرا؟ وغضب هروح ل state رقم 1؟ يبقى كدة استحالة افضل على state 0 (يعني $P_{00} = 0$).

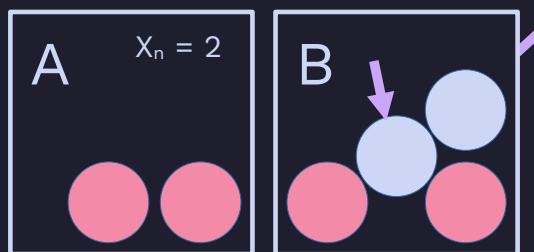
كدة انت في ملاحظتين ثلاثة مليت نص ال P تقربياً من غير ما تحس:

$$P = \begin{bmatrix} 0 & 1 & 0 \\ P_{10} & P_{11} & P_{12} \\ 0 & P_{21} & P_{22} \end{bmatrix}$$

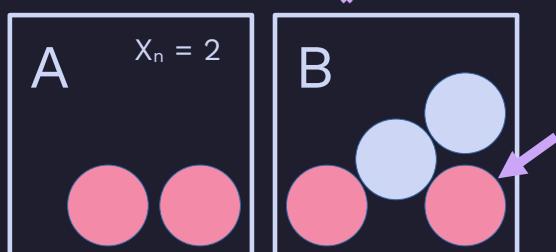
كدة انت فاضلك ايه في ال P؟ صف state رقم 1 كله وحبة من state رقم 2 ... ودول عشان نملاهم محتاجين نبص علي state رقم 1 ورقم 2 بالتفصيل الممل (اروح من 1 او 2 لباقي الحالات حتى نفسها ازاي؟):

من state رقم 2 لباقي ال states:

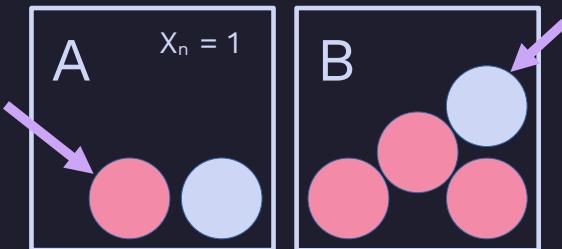
انا لو معايا كورتين حمر في الصندوق A وعايز اروح ل state رقم 1 يبقى هعوز اسحب كورة بيضا من B مش كدة؟ كدة هسحب كورة حمرا من A (احتمالية سحبها 1 ده لازم) وفي نفس الوقت واحدة بيضا من B (احتمالية سحبها $\frac{1}{2}$)... هضرب الرقمين في بعض زي اي احتماليين بيحصلوا مع بعض هيطلعلي $P_{21} = \frac{1}{2}$... في رسمة state رقم 2 هسحب من B اي واحد من دول:



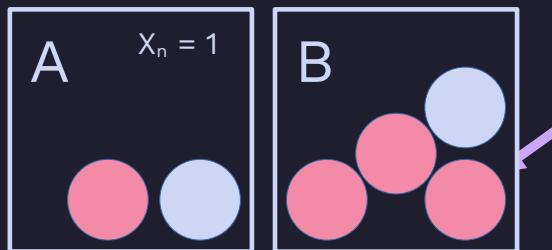
طب ينفع افضل في state رقم 2 زي ما انا؟ ينفع عادي و ساعتها بدل ما تسحب كورة بيضا من B هتسحب كورة حمرا (احتمالية سحبها $\frac{1}{2}$ برضه)... كدة معاك $P_{22} = \frac{1}{2}$ برضه... وفي الرسمة هتسحب من B اي واحدة من دول:



من state رقم 2 لباقي الـ:states ولو انا من state رقم 1 (معايا كورة حمرا واحدة بس في A) وعايز اروح لـstate رقم 0 (اخلي A كله كور بيضا بس)... فأنا ممكن اعملها يعني اسحب الكورة الحمرا من A (احتمالية سحبها $\frac{1}{2}$) ومعها اسحب الكورة البيضا من B (احتمالية سحبها $\frac{1}{4}$)... اضربهم في بعض زي اي احتمالين بيحصلوا مع بعض هيطلعك: $P_{10} = \frac{1}{8}$

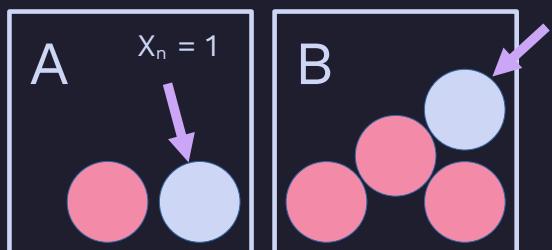


طب لو عايز اروح لـstate رقم 2 (وأقلب A كله كور حمرا)? هسحب الكورة البيضا من A (احتمالية سحبها $\frac{1}{2}$) ومعها هسحب واحدة من الكور الحمرا من B (احتمالية سحبهم $\frac{3}{4}$)... اضربهم في بعض كدة $P_{12} = \frac{3}{8}$

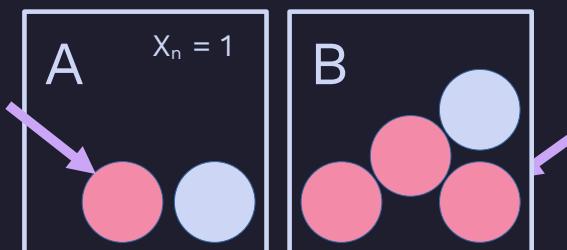


كدة مفاضليش غير احتمالية واحدة افضل في state رقم 1 زي ما انا... دي تتجاب بسكتين:

- يا اسحب الكورة البيضا من A (احتمالية سحبها $\frac{1}{2}$) والكورة الحمرا من B (احتمالية سحبها $\frac{1}{4}$):



- يا اسحب الكورة الحمرا من A (احتمال سحبها $\frac{1}{2}$) وواحدة من الكور الحمرا من B (احتمالية سحبهم $\frac{3}{4}$):



وفي الآخر هطلع P_{11} من ضرب كل سكة فيهم بعدين جمعهم:

$$P_{11} = \frac{1}{2} \times \frac{1}{4} + \frac{1}{2} \times \frac{3}{4} = \frac{1}{2}$$

وبكدة اكون كملت الـ P عندي بنجاح:

$$P = \begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{8} & \frac{1}{2} & \frac{3}{8} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix}$$

وطبعاً ممكن تجيب الـ π^1 عدل المرادي طالما معاك الـ P كاملة:

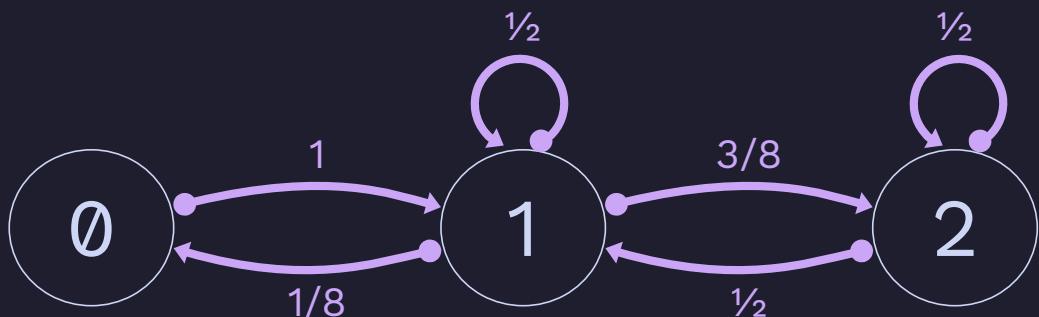
$$\pi^1 = \pi^0 P = [1 \ 0 \ 0] \begin{bmatrix} 0 & 1 & 0 \\ \frac{1}{8} & \frac{1}{2} & \frac{3}{8} \\ 0 & \frac{1}{2} & \frac{1}{2} \end{bmatrix} = [0 \ 1 \ 0]$$

- $P(X_1 = 1, X_2 = 1, X_3 = 2)$

آخر مطلوب اني اجيب احتمال ال intersection اللي معايا وده هرتبه وهفكه في ثانيتها:

$$\begin{aligned}
 & P(X_1 = 1, X_2 = 1, X_3 = 2) \\
 &= P(X_3 = 2, X_2 = 1, X_1 = 1) \\
 &= P(X_3 = 2 \mid X_2 = 1)P(X_2 = 1 \mid X_1 = 1)P(X_1 = 1) \\
 &= P_{12}P_{11}\pi_1^1 = \frac{3}{8} \times \frac{1}{2} \times 1 = \frac{3}{16}
 \end{aligned}$$

كدة انا خلصت المسألة بنجاح! ممكن برضه لو عايز ترسم one-step transition diagram عشان توضح معاك ال transitions اكتر هعملها لك عادي:



Lec3&4: Fixed-Point Distribution and Steady-State

1. بصن اعتبرها معادلة وحلها:

قالك وانا بجيبي الـ π time (iteration) قيمة كل π_i دى بتقرب لقيمة ثابتة بحيث اني لو ضربت الـ π دى في الـ P هتطبع زي ما هي:

$$\pi P = \pi$$

وانـت لو فـكـيـت كل حاجة فيـهـمـ لـ matrixـ وـ vectorـ هـتـعـرـفـ تـعـمـلـ معـاـدـلـتـيـنـ زـيـ الفـ تـحـلـهـمـ معـ بـعـضـ:

$$\begin{bmatrix} \pi_1 & \pi_2 \end{bmatrix} \begin{bmatrix} P_{11} & P_{12} \\ P_{21} & P_{22} \end{bmatrix} = \begin{bmatrix} \pi_1 & \pi_2 \end{bmatrix}$$

$$\pi_1 P_{11} + \pi_2 P_{21} = \pi_1$$

$$\pi_1 P_{12} + \pi_2 P_{22} = \pi_2$$

طبعاً دى الـ P اللي بنتكلـمـ عـلـيـهاـ يـعـنـيـ مـجـمـوعـ كـلـ صـفـ فـيـهاـ بـيـسـاـوـيـ 1ـ فـأـنـاـ اـسـتـحـالـةـ اـطـلـعـ بـحـلـ لـوـ جـمـعـتـ اوـ طـرـحـتـ كـلـ مـعـاـدـلـاتـ الـ matrixـ معـ بـعـضـ:

$$\pi_1 P_{11} + \pi_2 P_{21} + \pi_1 P_{12} + \pi_2 P_{22} = \pi_1 + \pi_2$$

$$\pi_1 (P_{11} + P_{12}) + \pi_2 (P_{21} + P_{22}) = \pi_1 + \pi_2$$

$$\pi_1 (1) + \pi_2 (1) = \pi_1 + \pi_2$$

فـأـنـاـ باـخـدـ مـعـاـدـلـةـ وـاحـدـةـ (اوـ كـامـ مـعـاـدـلـةـ لـوـ الـ P ـ اـبـعادـهـ اـكـبـرـ المـهـمـ مشـ كـلـهـمـ)ـ معـ مـعـاـدـلـةـ مـسـاعـدـةـ بـرـضـهـ بـطـبـقـهـاـ عـلـيـ الـ π ـ نـفـسـهـاـ:

$$\pi_1 + \pi_2 = 1$$

الـ fixed-point distributionـ دـهـ مـمـكـنـ اـجـيـهـ منـ ايـ **Markov chain**ـ واـيـ P ـ ...ـ الـ يـهـمـنـيـ بـسـ اـنـيـ اـحـلـ الـ مـعـاـدـلـاتـ الصـحـ معـ بـعـضـ الـأـوـلـ.ـ نـاخـدـ مـثـالـ بـأـرـقـامـ؟ـ

$$P = \begin{bmatrix} 0.3 & 0.7 \\ 0.5 & 0.5 \end{bmatrix}$$

Q: Find the fixed-point distribution for the following one-step transition matrix P.

الحل:

هتحط الـ P زي ما هي في فكة المعادلة بتاعتنا وتطلع منها المعادلتين بتوعك عادي:

$$\pi P = \pi$$

$$\begin{bmatrix} \pi_1 & \pi_2 \end{bmatrix} \begin{bmatrix} 0.3 & 0.7 \\ 0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} \pi_1 & \pi_2 \end{bmatrix}$$

$$0.3\pi_1 + 0.5\pi_2 = \pi_1$$

$$0.7\pi_1 + 0.5\pi_2 = \pi_2$$

هتاخد اول معادلة من دول (مثلاً) وهتحلها مع المعادلة المساعدة:

$$\pi_2 = 1 - \pi_1$$

$$0.3\pi_1 + (1 - \pi_1)0.5 = \pi_1$$

$$0.5 - 0.2\pi_1 = \pi_1$$

$$\pi_1 = \frac{5}{12}, \quad \pi_2 = \frac{7}{12}, \quad \pi = \left[\frac{5}{12}, \quad \frac{7}{12} \right]$$

2. ال steady-state

لو مسكتنا في ال P اللي كانت في المثال اللي فات عموماً:

$$P = \begin{bmatrix} 0.3 & 0.7 \\ 0.5 & 0.5 \end{bmatrix}$$

نقول مثلاً عايزين نجيبلها P بباور كبير زي P^7 (ال calculator مثلًا) هتساعد اوكي معاك عموماً ونقرب لأربع ارقام عشرية معاهم):

$$P^7 = \begin{bmatrix} 0.4167 & 0.5833 \\ 0.4167 & 0.5833 \end{bmatrix}$$

لو كملنا على نفس المنوال P^∞ (او لعدد كبير برضه ميضرش) هلاقي ان ال P^n يعتبر مبتنغيرش كل ما اضرب فيها P ...

$$\lim_{n \rightarrow \infty} P^n = \lim_{n \rightarrow \infty} \begin{bmatrix} 0.3 & 0.7 \\ 0.5 & 0.5 \end{bmatrix}^n = \begin{bmatrix} 0.41\bar{6} & 0.58\bar{3} \\ 0.41\bar{6} & 0.58\bar{3} \end{bmatrix}$$

معني اصح:

$$P^n = P^{n+1}$$

كدة بنقول ان ال P اللي ال $Markov$ chain من **steady-state** هي كدة **هتخشن** في π^0 ممكن ابدأ ال $process$ بتاعتي منها... وكمان ال π^n هتقرب لل π^0 بتاعتتها $distribution$ (نظرياً):

$$\pi^n = \pi^0 P^n, \quad \pi^{n+1} = \pi^0 P^{n+1}$$

$$\therefore P^n = P^{n+1}, \quad \therefore \pi^n = \pi^{n+1} = \pi$$

$$\pi^{n+1} = \pi^0 P^n P = \pi^n P = \pi P$$

$$\pi P = \pi$$

المهم بس فيه شرط اساسي عشان اوصل لكل الكلام ده... ان عند n معينة الباقي ان كل القيم اللي في P اكبر من واحد (لو فيه اصفار كانت في الـ P الاصلية هتتشال)... يعني ممكن يبقى كل ده بعد $n=2$ او $n=3$ او حتى $n=10$ المهم اوصل P مفيهاش ولا صفر:

$$P_{ij}^n > 0 \text{ for all } i, j$$

المهم هل فيه مثال ان فيه ماتريكس ممكن تبقي عكس كدة؟ حصل... عندك مثلاً ابسط مثال لو في P كانت 2×2 Markov chain:

$$P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

دي انت لو جربت انك تجيب P^2 هتبدل الوحدات بالإصفار، ولو جربت تجيب P^3 هتبدل الوحدات بالإصفار مرة كمان وهتبقي بتساوي الـ P ، وهكذا:

$$P^2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad P^3 = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = P, \quad P^4 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = P^2, \quad \dots$$

ماتريكس زي دي هتللاقيقها بتتنط ما بين الـ P والـ P^2 مع كل باور ليها (كل باور فردي = وكل باور زوجي = $(P^2)^k$)... فبنقول ان استحالة الـ P دى تخشن في $P^{n+1} \neq P^n$ عشان دايماً state

Lec4 (Cont.): Gambler's Game and Classification of States

ال states وتصنيف ال gambler's game

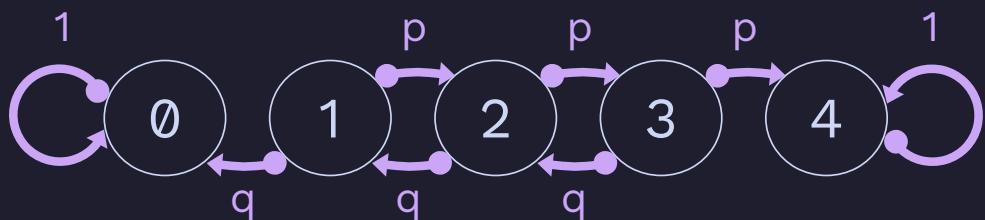
بص علي قد ما دي لعبه في اسمها لعب علي فلوس وقامار اصلاً بس مهم اننا نعرف فيها كام حاجة في تصنيف ال states جوا اي **Markov chain** عموماً فركل معايا في شروطها:

- انا معايا عدد معين من الجنيهات (جنيه او اتنين او ثلاثة وهكذا) وبلعبة لعبه معينة.
- لو انا كسبت (احتمال الفوز p) فأنا هكسب جنيه، ولو انا خسرت (احتمال الخسارة q) هخسر جنيه.

- لو انا وصلت لعدد جنيهات معين (نقول 4) يبقى خلصت الفوره وهخلع بالفلوس كلها ومتش هلعب تاني.

- ولو انا خسرت كل فلوسي (معايا 0) يبقى فارت عليا وفلست ومبقاش معايا حاجة العب عليها.

بديهيا هرسم ال states للعبه دي ازاي؟ دلوقتي انا ال states عندي عدد الجنيهات اللي معايا يعني هيبيقي عندي كدة 5 حالات (من 0 لـ 4)... بص علي الرسمة دي مبدئياً وهشرحلك بعديها ال states عاملة ازاي بعديها:



هقول علي اكتر من ملحوظة ورا بعض وركز عشان كل ملحوظة ببني عليها اللي بعديها:

ملحوظة #0:

اي سكة انا ممكن امشي فيها عباره عن sequence of transitions بتتحول فيها من state للتنمية... وبسمي اي سكة فيهem **path** او طريق.

ملحوظة #1:

من اول كام حاجة هتاخد بالك منها غير ال p وال q الوحيد اللي علي ال 0 وال 4... ودول ببساطه يعني لو انا وصلتلهم مش هعرف اطلع منهم... يعني كدة عندك $P_{00} = 1$ وكمان $P_{44} = 1$... دول بنسميهem ال **absorbing states** او الحالات الجاذبة... بشكل عام اي absorbing state رقم i ممكن يتزمزلها كالتالي:

$$P_{ii} = 1$$

ملحوظة #2:

انا ممكن اوصل من 1 state ل state 4 ... فممكن اقول ان:

$1 \rightarrow 4$ (state 4 is **accessible** from state 1)

او ان state 4 متاحة من state رقم 1.

وبرضه لو انا في state 4 استحالة اوصل منها ل state 1 ... فبرضه ممكن اقول ان:

$4 \not\rightarrow 1$ (state 1 is **inaccessible** from state 4)

او ان state رقم 1 غير متاحة من state رقم 4.

ملحوظة #3:

لو لقيت اي اتنين states متاحين من بعض:

$1 \rightarrow 3, 3 \rightarrow 1$

اقدر اقول ان:

$1 \leftrightarrow 3$ (states 1 and 3 are **communicating** states)

او ان states رقم 1 و 3 بيتواصلوا مع بعضيهما.

ملحوظة #4:

لو لقيت كذا communicating state ورا بعض ممكن اجمعهم في class او فئة لوحدها (نسميها C_1 للتبسيط):

$1 \leftrightarrow 2, 2 \leftrightarrow 3, 1 \leftrightarrow 3$

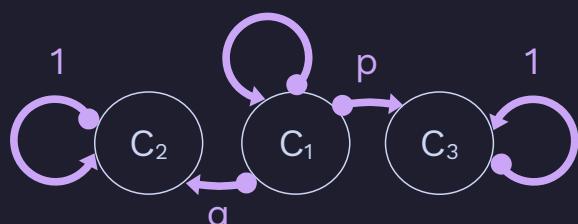
$C_1 = \{1,2,3\}$

ولما بكتب ال classes ممكن ارمي كل state باقية في class لوحدها (حتي لو قولنا عليهم في ملحوظة #1 انهم absorbing states لأنهم لا يمش سبب احطهم مع بعض):

$C_1 = \{1,2,3\}, C_2 = \{\emptyset\}, C_3 = \{4\}$

ملحوظة #5:

لو علي التقسيمة بتاعت ال classes اللي فوق لقيت فيه اكتر من class فممكن اقول تلقائي انه ممكن اختصر كل class فيهم مع بعضه (زي الرسمة اللي جنبي كدة).



ويبيقي ساعتها ال Markov chain دي **reducible** او قابلة للإختصار... بالعكس بقى لو لقيتهم كلهم في واحد فممكن اقول ان ال Markov chain دي **irreducible** غير قابلة للإختصار.

ملحوظة #6

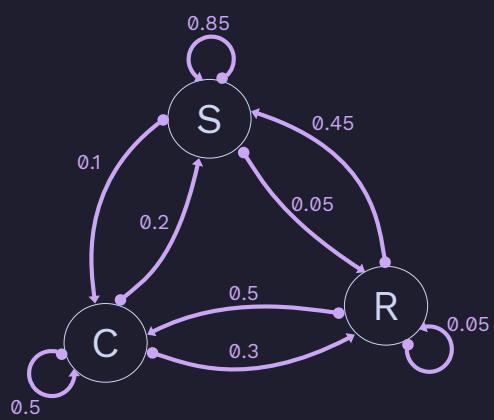
ارجع لـ Markov chain بتعات اللعبه تاني كدة... لو فيه state انا ممكن اطلع منها في اي path من غير ما ارجع لها تاني (زي ما بروح من اي state لـ 4 او لـ 0 ومش هعرف ارجع) ممكن نقول على الـ state دى transient state او مؤقتة استحالة ارجع لها تاني لو طلعت منها في path واحد عالاقل:

Transient state is a state that has at least one path where we can leave the state without returning back to it.

ملحوظة #7

بالعكس بقى بس في Markov chain تانية زي المثال الكلاسيكي بتاع الـ weather اللي شوفناه في الأول... لو فيه اي state انا لازم وحتماً ولابد ارجع لها تاني دى بسميه recurrent state او متكررة لازم ارجع لها تاني بعدين.

يعنى مثلاً انا لو في S ممكن امشي في اي path براحتي انشالله ابات عند R و بس ممكن ارجع بأي احتمالية لـ S عادي... فتعتبر الـ S دى recurrent state (وكلهم recurrent state اصلاً مساء الفل عشان ببساطة الـ chain كلها irreducible وكل حالاتها不可沟通的).



Recurrent state is a state where it's certain that it's possible to return to that state.

او ان الـ recurrent state دي انا متأكد مليون في المية انا ممكن نرجع لـ state دى بعد ما طلعننا منها.

كدة خلصنا الملحوظات مؤقتاً وهنلخصهم سريعاً كدة:

- **Path:** sequence of transitions (سلسلة من التحولات).
- **Absorbing state:** (حالة لازم افضل عندها زي ما هي) $P_{ii} = 1$
- **Accessible state** (B is accessible to A): $A \rightarrow B$
- /- **Inaccessible state** (B is inaccessible to A): $A \not\rightarrow B$
- **Communicating states** (A and B are communicating states): $A \leftrightarrow B$
- **Class:** collection of communicating states: $C = \{ \dots, \dots, \dots \}$
- **Reducible chain:** Markov chain with more than one class.
- /- **Irreducible chain:** Markov chain with only one class.
- **Transient state:** Cannot return to state in at least one path.

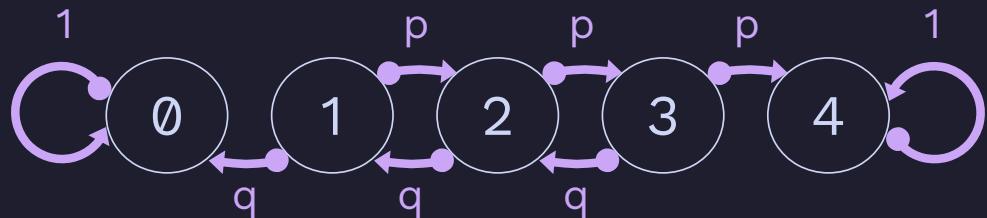
(فيه سكة واحدة عالاقل منها اللي يروح ميرجعش)

- /- **Recurrent state:** Can return to state in all possible paths.
(لو مشيت منها ممكن ارجع لها في اي وقت عادي)

Lec5: Gambler's Game and Probability Calculations

1. تقسيمة ال P في ال gambler's game

طب ايه احتمالية اني افضل في ال transient او اني اروح منها لل absorbing في نهاية المطاف (لما اوصل للملائحة؟) ده اللي هنعرفه لما نرجع للعبة بتاعتنا تاني ونفصصها واحدة واحدة ونحسب ايه ال P^n اللي عايزينها منه دي:



$$P = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ q & 0 & p & 0 & 0 \\ 0 & q & 0 & p & 0 \\ 0 & 0 & q & 0 & p \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

طب دول ومترتبين من 0 ل 4 بأرقام ال states ... طب لو رتبناهم بال classes وخلينا كل ال transient (اللي هما $C_1 = \{1, 2, 3\}$) الأول؟ نشوف كدة هيطلع معايا ايه:

$$P = \begin{bmatrix} 1 & 2 & 3 & 0 & 4 \\ 1 & 0 & p & 0 & q & 0 \\ 2 & q & 0 & p & 0 & 0 \\ 3 & 0 & q & 0 & 0 & p \\ 0 & 0 & 0 & 1 & 0 \\ 4 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

ونقسم الـ P برضه اربع اربع (ممكنا تشفوفها احنا لسة في الـ transient ولا روحنا منها ولا لأنها absorbing):

$$P = \begin{array}{c|ccccc} & 1 & 2 & 3 & 0 & 4 \\ \hline \begin{matrix} 1 \\ 2 \\ 3 \\ 0 \\ 4 \end{matrix} & \left[\begin{array}{cc|cc} 0 & p & 0 & q & 0 \\ q & 0 & p & 0 & 0 \\ 0 & q & 0 & 0 & p \\ \hline 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{array} \right] \end{array}$$

دلوقي احنا ممكنا نقسم الربعين اللي فوق Q فوق عالشمال (مكان الـ R و Q)... حاجة رايحة من **transient** (مكان اي حاجة حاجة... وبما ان مينفعش ارجع من Q transient absorbing فالربع اللي تحت عالشمال بـ 0 ، وبرضه بما اني اكيد هفضل في اي absorbing state بعد ما وصلتلها فالربع اللي تحت عاليمين بـ 1 (مش بالواحد بتاعنا لأنها... بالواحد بتاع الـ **matrices** يعني I او الـ **identity matrices**):

$$P = \left[\begin{array}{c|c} Q & R \\ \hline 0 & I \end{array} \right]$$

نرجع نوضحلك هدفنا اللي قولته في اول **Lec5** اللي احنا فيه... احنا عايزين P^n اما توصل للمالانهاية فإن كنتها على صورة نهاية او limit (وده بنسميه بعد كدة بالـ **absorbing probability** او الاحتمالية الجاذبة وهتعرف ليه قريب):

$$\lim_{n \rightarrow \infty} P^n$$

$n \rightarrow \infty$

يعني هتقعد تضرب الـ P في نفسها كذا مرة... والـ P^2 مبدئياً كدة:

$$P^2 = \left[\begin{array}{c|c} Q & R \\ \hline 0 & I \end{array} \right] \left[\begin{array}{c|c} Q & R \\ \hline 0 & I \end{array} \right] = \left[\begin{array}{c|c} Q^2 & QR + R \\ \hline 0 & I \end{array} \right]$$

وكمان مرة لما نجيب الـ P^3 :

$$P^3 = \begin{bmatrix} Q & R \\ 0 & I \end{bmatrix} \begin{bmatrix} Q^2 & QR+R \\ 0 & I \end{bmatrix} = \begin{bmatrix} Q^3 & Q^2R+QR+R \\ 0 & I \end{bmatrix}$$

هتاخد بالك كدة من كام نمط مهمين... الربعين اللي تحت بتوع الـ 0 والا مش بيتغيروا (وبالمنطق عمرهم ما هيتغيروا) وكل اللي بيتغير الربعين اللي فوق... الـ Q بتنضرب في نفسها والـ R بيتضاف عليها كل مرة Q بباور اكبر مضروب في R برضه... فإنـت لما تيجي توصل للـ P^n هتوصل للمنظر ده:

$$P^n = \begin{bmatrix} Q^n & Q^{n-1}R + Q^{n-2}R + \dots + Q^2R + QR + R \\ 0 & I \end{bmatrix}$$

دلوقي هنبدأ نجيب الـ limit بتاع الـ P^n او الـ absorbing probability زي ما قولنا... مبدئياً كدة:

$$\lim_{n \rightarrow \infty} Q^n = 0$$

لو جربت تحسبها مع نفسك هتطلع كدة (او حتى بالمنطق استحالة افضل في حالة transient للأبد فلازم فيه نقطة اطلع منها للـ absorbing). كدة افضلنا الربع اللي فوق عاليمين وده يحتاج شغل شوية... خد الـ R عامل مشترك الأول نشتغل علي نضافة:

$$\begin{aligned} \lim_{n \rightarrow \infty} Q^{n-1}R + Q^{n-2}R + \dots + Q^2R + QR + R \\ = \lim_{n \rightarrow \infty} (Q^{n-1} + Q^{n-2} + \dots + Q^2 + Q + I)R \end{aligned}$$

بس الأول خلينا نبص علي قانون مشهور نوعاً ما بتاع الـ geometric series (اثباته معلومة اثرائية عليك وفيه Taylor expansion عند 0 من هنا):

$$\sum_{n=0}^{\infty} x^n = 1 + x^2 + x^3 + \dots = \frac{1}{1-x}$$

طبعاً ممكن تطبق الكلام الجميل ده علي حبة الـ Q اللي خدت الـ R منهم عامل مشترك... وبما ان الـ Q ماتريكس فإنت **هتقلب كل حاجة عندك لنسختها في** $(I-Q)^{-1}$ (المقلوب inverse بـ I والواحد بـ Q) **matrices** الـ

$$\lim_{n \rightarrow \infty} (Q^{n-1} + Q^{n-2} + \dots + Q^2 + Q + I) R = (I - Q)^{-1} R$$

كدة كمل عندك الـ P^n بنجاح:

$$\lim_{n \rightarrow \infty} P^n = \begin{bmatrix} 0 & (I - Q)^{-1} R \\ 0 & I \end{bmatrix}$$

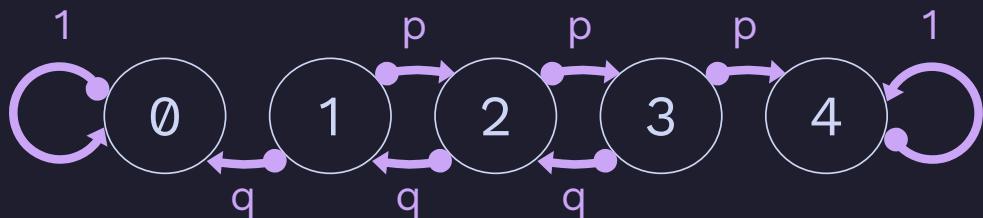
كدة عرفت ليه سميانا الليميـت ده بالذات الـ **absorbing probability** عشان ده اللي بيقولك كل الاحتمالات للـ **absorbing states** (بما ان الاحتمالات للـ **transient states** بـ 0 بالغصب).

2. ابسـط مـثال من اللـعـبة نفسـها بالـحل:

In gambling game, the probability for winning p is 0.6 and the probability of losing q is 0.4. The state space S for the game is $\{0,1,2,3,4\}$, with 0 and 4 as end states. Find absorbing probability for the game.

الـحل:

هـنا يـدوـبك أـخـد نـفـسـ المـثـال اللي شـرـحـناـه وـحـطـ مـكـانـ الـ p وـالـ q اـحـتمـالـهـم... طـبـ ماـشـي خـلـينـي اـمـشـي بـبـسـاطـة وـرـاه عـشـان غـصـبـ هـلـ حلـ كـلـ مـسـأـلةـ منـ الـأـوـلـ:



وهطلع بقى منها الـ P اللي هنفصصها بعددين:

$$P = \frac{\left[\begin{array}{ccc|cc} 0 & p & 0 & q & 0 \\ q & 0 & p & 0 & 0 \\ 0 & q & 0 & 0 & p \end{array} \right]}{\left[\begin{array}{ccc|cc} 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{array} \right]} = \left[\begin{array}{ccc|cc} 0 & 0.6 & 0 & 0.4 & 0 \\ 0.4 & 0 & 0.6 & 0 & 0 \\ 0 & 0.4 & 0 & 0 & 0.6 \end{array} \right]$$

احنا هنا عارفين مين الـ Q ومين الـ R بتاعتنا فبساطة هنجيب الـ absorbing probability من القانون:

$$\lim_{n \rightarrow \infty} P^n = \left[\begin{array}{c|c} 0 & (I-Q)^{-1}R \\ \hline 0 & I \end{array} \right]$$

وهنجيب $(I-Q)^{-1}R$ بالألة عادي... هتدخل $I-Q$ في MatA (كل الماتريكس معاك بالسالب مع عدا القطر هتطرحه من وحайд) و R في MatB ومبروك عليك ناتج الربع:

$$(I-Q)^{-1}R = \left[\begin{array}{ccc} 1 & -0.6 & 0 \\ -0.4 & 1 & -0.6 \\ 0 & -0.4 & 1 \end{array} \right]^{-1} \left[\begin{array}{cc} 0.4 & 0 \\ 0 & 0 \\ 0 & 0.6 \end{array} \right] = \left[\begin{array}{cc} 0.585 & 0.415 \\ 0.308 & 0.692 \\ 0.123 & 0.877 \end{array} \right]$$

ومعاها هتكمل الـ absorbing probability على طول وتبقي مسألتك خلصت:

$$\lim_{n \rightarrow \infty} P^n = \left[\begin{array}{ccccc} 0 & 0 & 0 & 0.585 & 0.415 \\ 0 & 0 & 0 & 0.308 & 0.692 \\ 0 & 0 & 0 & 0.123 & 0.877 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{array} \right]$$

3. مثال كمان نراجع بيه علي كل اللي فات:

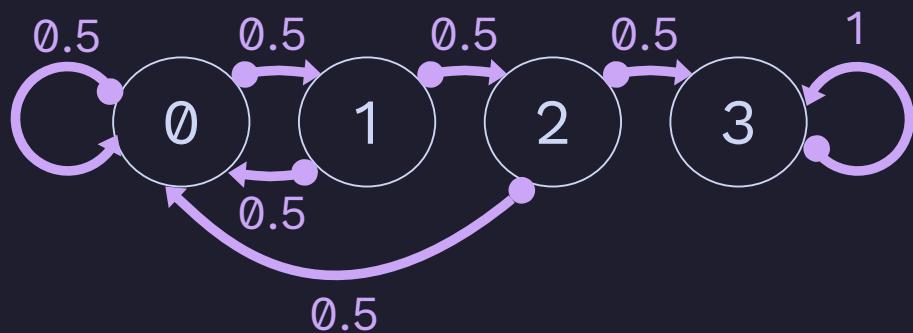
A fair coin is flipped until three heads occur in a row. Find the one-step transition matrix P and the absorbing probability.

احنا بنقعد نرمي عملة لحد ما نجي 3 ملك ورا بعض. احسب ال P وال absorbing probability

الحل:

بص... هي كدة كدة فيها فكرة فكرز معايا انا فكرت فيها ازاى: انا عايز ال states بتاعتي تبقي زي عدد بعد ورايا انا جبت كام head ورا بعض (يعني كدة $S = \{0,1,2,3\}$). هنا انا كل ما اجي head يطلع على ال state اللي اعلى منها، وكل ما اجي tail ارجع لل 0 تاني... وبرضه لو وصلت لل 3 تكون خلاص وحققت هدفي... يعني state رقم 3 هتبقي absorbing state

تعالي نرسم بقى ال diagram بتاعها عشان نوضح اكتر (طالما قولنا fair يعني احتمالية ال head وال tail بيساواوا بعض بـ 0.5 عادي):



وعادي انا حاطط $P_{00} = 0.5$ هنا عشان اكيد ممكن ارمي tail في الأول خالص وارجع لنفس النقطة، او اي عدد من ال tails ورا بعض انا بفضل في ال 0 برضه.
المهم يعني ممكن نعمل من ده ال P علي طول:

$$P = \left[\begin{array}{ccc|c} 0.5 & 0.5 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 \\ 0.5 & 0 & 0 & 0.5 \\ \hline 0 & 0 & 0 & 1 \end{array} \right]$$

وطبعاً مقدرش اوصيك تاني ان state رقم 3 هو اخر صف واخر عمود.

كمان مرة طالما طلعننا الـ P وعرفنا مين الـ Q ومين الـ R يبقي سهل نطلع الـ $(I-Q)^{-1}R$
بالألهة ومعاها والـ :absorbing probability

$$\lim_{n \rightarrow \infty} P^n = \begin{bmatrix} 0 & | & (I-Q)^{-1}R \\ 0 & | & I \end{bmatrix}$$

$$(I-Q)^{-1}R = \begin{bmatrix} 0.5 & -0.5 & 0 \\ -0.5 & 1 & -0.5 \\ -0.5 & 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 \\ 0 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$\lim_{n \rightarrow \infty} P^n = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Lec6: Expected Number of Visits and Discrete Markov Chains

1. الـ expected number of visits :

لو انا جبت عداد يعدلني انا روحت state معينة بعد n خطوات وسميت العداد ده I_n (لو انا في الـ state فبيساوي 1 وان انا مش فيها فبيساوي 0)... فأنا ممكن اجيبي الـ expected number of visits عدد المرات اللي هزور فيها الـ state دي قبل ما اخشن في اي absorbing state (وده معناه الـ expectation بتاع مجموع الـ I_n او مبني اصح مجموع الـ infinity عند كل n لحد الـ n)

$$E\left(\sum_{n=0}^{\infty} I_n\right) = \sum_{n=0}^{\infty} E(I_n)$$

المهم يعني عشان ده expected value state فكل expectation بتاعتتها (لو الـ I_n بيساوي 1) احتمال اني اروح للـ state ديه اصلاً بعد n خطوة (مضروب في احتمال الـ state اللي انا فيها اللي بيساوي 1 كدة كدة)... طالماحتاج ده يبقي للـ transient بس يبقي انا ممكن اكتر الحوار علي الـ Q من Lec5 اللي فات:

$$\text{Expected # of visits} = \sum_{n=0}^{\infty} Q^n$$

واللي عرفنا برضه ان الـ \sum ده بالذات بيساوي:

$$\text{Expected # of visits} = (I - Q)^{-1}$$

طبعاً ممكن اطبق الكلام الجميل ده علي اي Markov Chain زي مثال العملة اللي فات:

$$(I - Q)^{-1} = \begin{bmatrix} 0.5 & -0.5 & 0 \\ -0.5 & 1 & -0.5 \\ -0.5 & 0 & 1 \end{bmatrix}^{-1} = \begin{bmatrix} 8 & 4 & 2 \\ 6 & 4 & 2 \\ 4 & 2 & 2 \end{bmatrix}$$

ولو حبينا نعرف الـ expected number of visits من اي حالة ببساطة بجمع الصف بتاعها كلها... يعني من state رقم 2 بالذات انا تحتاج اجمع $6+4+2=12$ عشان اعرف ان الـ expected number of steps from state 2 هيطلع بـ 12.

2. ال hitting time وال probability of first return

المرادي بدل ما بجيب احتمالية اني هروح الى state عموماً ايًّا كان عديت عليها قبل كدة ولا لأ المرادي انا باخد بالي من ان يكون وصولي لل state دى اول وصول... خلينا نبدأ الأول بإنني اعرّف احتمالية اني ارجع لل state دى اول مرة بعد ما مشيت منها بعد خطوة (وهنرمتلها بالرمز f_{ii}^n):

$$f_{ii}^n = P(X_n = i, X_{n-1} \neq i, \dots, X_1 \neq i \mid X_0 = i)$$

يعني انا بروح من الألي state تانية غير الا لحد اما ارجع لـ تاني في n خطوات بالظبط... ممكن تاخد بالك ان لو الـ n بـ 1 يبقى معانيا self-transition العادي P_{ii}

$$f_{ii}^1 = P(X_1 = i \mid X_0 = i) = P_{ii}$$

هنا بقى هبدأ اعرّف كمان حاجة جديدة وهي f_i (او f_{ii} باختصار واسمها **probability of first visit** او **first return**) وده احتمال اني اروح وارجع للـ تاني مرة على طول عموماً يعني مجموع كل f_{ii}^n لحد ما الـ n توصل لـ **infinity**

$$f_i = \sum_{n=1}^{\infty} f_{ii}^n$$

والـ f_i هي اللي بتحدد اذا كانت الـ state اللي انا فيها دى recurrent ولا ...recurrent transient

$f_i = 1 \rightarrow$ state i is **recurrent**.

$f_i < 1 \rightarrow$ state i is **transient**.

او ان لو الـ f_i بتساوي 1 اللي هو انا متأكد اني هرجع لـ تاني يبقى اكيد الـ i دى ...anma غير كدة تبقي الـ i دى **transient** عادية.

ثالث حاجة جديدة هعرفها هي الـ m_i (اختصارها m_i او μ_i واسمها الـ **hitting time** او الـ **recurrence time**) وده الوقت او عدد الخطوات اللي متوقع اخدها عشان اوصل تاني للـ state اللي كنت فيها تاني مرة، وده ليه قانون صعب شوية نحسبه:

$$m_i = \sum_{n=1}^{\infty} n f_{ii}^n$$

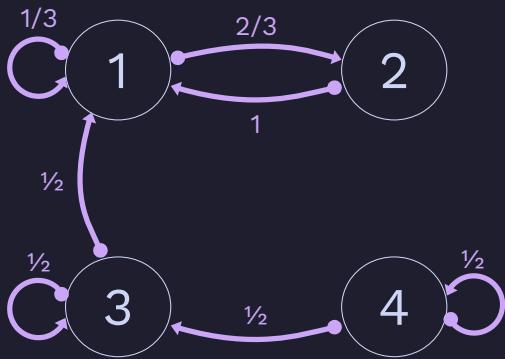
بس عرفنا قانون تاني ليه (ملناش دعوة بـ ثباته عموماً) سهل نقدر حسب منه الـ m_i بسهولة لو معانا الـ π_i (ودي الـ π بتاعت steady-state من Lec4 لو تفتركتها):

$$m_i = \frac{1}{\pi_i}$$

3. مثال على ال probability of first return

Q: Given this Markov chain diagram.

- State using f_{ii^n} if states 2 and 4 are recurrent or transient.
- Obtain expected number of steps needed to return to state 1.



الحل:

خلينا الأول نجيب ال P من ال diagram ده (وهخلية في الجنب عشان بياخد مني طول في الكتابة اصلاً).

خلينا في اول مطلوب بتاع ال f_{ii^n} وعموماً قاعدتنا ثابتة لما نيجي نحسب ال f_2 وال f_4 لو = 1 يعني recurrent لو > 1 transient يعني.

هنبدأ ب state 2 رقم 2 (او f_2) علي طول وهنفصصها واحدة واحدة من اول واحد $: f_{22}^1$

$$f_{22}^1 = P_{22} = 0$$

وده عشان مفيش اي self-transition ممكن اعمله من 2 عشان ارجع لها تاني... نخش في $: f_{22}^2$

$$f_{22}^2 = P_{21} P_{12} = 1 \times \frac{2}{3}$$

روحت من 2 ل 1 بعدين رجعت ل 1 تاني... طب $? f_{22}^3$

$$f_{22}^3 = P_{21} P_{11} P_{12} = 1 \times \frac{1}{3} \times \frac{2}{3}$$

هنا انا روحت من 2 ل 1 برضه بعدين لفيت في self-transition مرة واحدة عند ال 1 بعدين رجعت ل 2 (هسيب الضرب متفرد عشان الشرح)... طب $? f_{22}^4$

$$f_{22}^4 = P_{21} P_{11} P_{11} P_{12} = 1 \times \frac{1}{3} \times \frac{1}{3} \times \frac{2}{3} = 1 \times \left(\frac{1}{3}\right)^2 \times \frac{2}{3}$$

برضه نفس اللي عملناه في f_{22}^3 بس المرادي لفينا مرتين عند 1... ايه ده يعني كل مرة
كمان هضرب في P_{11} يعني $1/3$? بالضبط كدة... حتى انك ممكن تعمم كل ده في قانون
ثابت لما تيجي تحسب الـ f_2 علي بعضها:

$$\begin{aligned} f_2 &= \sum_{n=1}^{\infty} f_{22}^n = 0 + \frac{2}{3} + \frac{2}{3} \left(\frac{1}{3} \right) + \frac{2}{3} \left(\frac{1}{3} \right)^2 + \dots \\ &= \frac{2}{3} \left(1 + \frac{1}{3} + \left(\frac{1}{3} \right)^2 + \dots \right) \\ &= \frac{2}{3} \left(\frac{1}{1 - \frac{1}{3}} \right) = \frac{2}{3} \left(\frac{3}{2} \right) = 1 \end{aligned}$$

برضه استعملنا نفس قانون الـ geometric series اللي معايا عشان احول كل اللي
جمعته لكسر بسيط $2/3$ اضربه في الـ $2/3$ عشان يساوي 1... وبكدة يبقي عرفنا ان

recurrent state رقم 2 بقى

نخش علي state رقم 4 وبنفس الطريقة نفصص f_4 من اول f_{44}^1 :

$$f_{44}^1 = P_{44} = \frac{1}{2}$$

طبعاً عشان self-transition اللي عند الـ 4... طب لو بصيت عالشكل بالعقل مش
هعرف ارجع تاني اصلاً لـ state رقم 4

$$f_{44}^2 = 0, f_{44}^3 = 0, f_{44}^4 = 0, \dots$$

يعني كدة الـ f_4 كلها بـ $\frac{1}{2}$:

$$f_4 = \sum_{n=1}^{\infty} f_{44}^n = \frac{1}{2}$$

وبكدة نبقي عرفنا ان state رقم 4 هتبقي **transient**

تاني مطلوب بتاع ال recurrence time (بالبلدي ال expected number of steps) ده مطلوب مني علي state رقم 1 يعني مطلوب مني m_1 ... هنا هشتغلها بالطريقة الصعبه (سيبيك من السهله دلوقتي وهو ضحلك ليه).
نبداً واحدة واحدة نحسب ال f_{11}^1 :

$$f_{11}^1 = P_{11} = \frac{1}{3}$$

: f_{11}^2 ووراها نحسب ال

$$f_{11}^2 = P_{12} P_{21} = \frac{2}{3} \times 1 = \frac{2}{3}$$

طبعاً مش هتعرف تجيب اكتر من كدة عشان استحالة تقعد برا 1 من انك تقعد في رقم 2 مرة بالعدد وترجع تاني... فكدة:

$$f_{11}^3 = 0, f_{11}^4 = 0, f_{11}^5 = 0, \dots$$

كدة هجيب ال m_1 باني هجيب كل f_{11}^n وهمضرب فيها ال n بتاعتتها واجمعهم مع بعض:

$$m_1 = \sum_{n=1}^{\infty} n f_{11}^n = 1 \times f_{11}^1 + 2 \times f_{11}^2 = 1 \left(\frac{1}{3} \right) + 2 \left(\frac{2}{3} \right) = \frac{5}{3}$$

ليه بقى محسبيتش بالطريقة السهله؟ عشان اصلاً ال P مليانه اصفار (ولسه هيقي فيها اصفار لما اجيبي ليميت ال P^n) فمش هعرف اطلع منها ب steady-state ودائماً لو ملقتتش ال P بتخشن steady-state بقى متقربيش من الطريقة السهله.
بس عموماً لو جيت حسبت ال fixed-point distribution بتاعها π هتبقي كدة:

$$\pi = \begin{bmatrix} 3 & 2 & 0 & 0 \\ 5 & 5 & & \end{bmatrix}$$

وباللحظة هتلقي ان:

$$m_1 = \frac{1}{\pi_1}$$

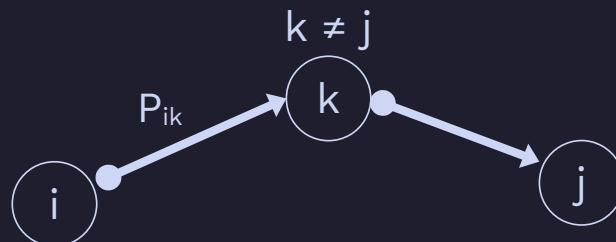
وده مش دايماً بيحصل مع اي P مبتخشش في steady-state ... اللي حصل فهلوه كون ان states رقم 1 و 2 في recurrent class لوحدهم.

الـ 4. first-hitting time

انا ممكن برضه اعرف الـ f_{ij}^n على اي اتنين states عندي i و j زي مثلاً :

$$f_{ij}^n = P(X_n = j, X_{n-1} \neq j, \dots, X_1 \neq j \mid X_0 = i)$$

ده بقى بالذات ممكن افهمه بحاجة بسيطة: انا لو سميت الـ state اللي بروحها بعد اول خطوة بـ k (وممكن بعديها اروح من k لـ j في اي عدد خطوات انا عايزه ول يكن $n-1$):



ساعتها زي شرح الأسهوم في [Lec2](#) انا بضرب الاتنين في بعض (والمرادي انا بعدد في الـ k مش الـ n او بمعني اصح كل الـ states غير الـ j ... وعادي لو الـ k بقت ا علي فكرة):

$$f_{ij}^n = \sum_{k, k \neq j} P_{ik} f_{kj}^{n-1}$$

يعني مثلاً ممكن تاخد بالك ان لو عندي state space زي $S = \{1, 2, 3\}$ وقالك انا عايز اوصل اول مرة لـ state رقم 3 من state رقم 2، ساعتها هعدد الـ k معايا تبقي اي تانية غير الـ 3 ($k \in \{1, 2\}$ يعني $\{k\} = \{1, 2\}$):

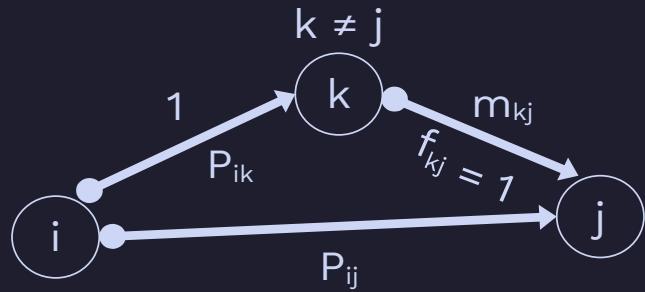
$$\begin{aligned} f_{23}^2 &= \sum_{k, k \neq j} P_{2k} f_{k3}^1 \\ &= P_{21} f_{13}^1 + P_{22} f_{23}^1 = P_{21} P_{13} + P_{22} P_{23} \end{aligned}$$

دلوتي انا برضه ممكن اعرف الـ m_{ij} (ونسميها شبه اخوها الـ m_{ij}) او الـ m_i زي الـ m_i دي عدد المرات اللي متوقعها عشان اوصل من i لـ j اول مرة، فقانونها شبه الـ m_{ij} وهرجع اعدد فيها الـ n :

$$m_{ij} = \sum_{n=1}^{\infty} n f_{ij}^n$$

وطبعاً ده القانون الاصعب وهنا جايلك عشان القانون السهل بإثبات تقيل حبتين الصفحة الجاية.

دلوقي هنرجع لنفس شكل الاسهم بتاع الـ f_{ij} بس هزود عليه كذا حاجة:



دلوقي انا حطيت فوق الأسهم عدد المرات اللي تحتاجها عشان اروح من الـ states في الخطوة، وتحت الخطوة دي... فكدة كدة انا من ا لو مشيت في اول سكة ($n > 1$) ممكن اعدي علي k في اول خطوة احتمالها P_{ik} وبعديها تاني خطوة احتمالها f_{kj} (وبما اني معتبر الـ k فكدة ومؤكد اني اروح لـ j فعندي $f_{kj} = 1$)، وممكن برضه اروح من ا لـ j على طول في خطوة واحدة ($n = 1$) احتمالها P_{ij} ... المهم يعني هنا انا ضربت عدد الخطوات بتاعت كل سكة مشيت فيها ($1 + m_{kj}$ في اول سكة) في احتمالية السكة دي:

$$m_{ij} = (1)P_{ij} + \sum_{k, k \neq j} (1 + m_{kj})P_{ik} f_{kj} = P_{ij} + \sum_{k, k \neq j} P_{ik} (1 + m_{kj})$$

بعد كدة نوزع الـ $\sum_{ik} P_{ik}$ في القوس اللي جواها:

$$m_{ij} = P_{ij} + \sum_{k, k \neq j} P_{ik} + \sum_{k, k \neq j} P_{ik} m_{kj}$$

ركز بقى معايا... الـ $\sum_{ik} P_{ik}$ والـ $\sum_{ik} P_{ik}$ مع بعض دول مدیني كل اللي طلع من ا بلا استثناء (يعني كدة مجموعهم بـ 1)... وبس كدة بقى معاك المعادلة السهلة:

$$m_{ij} = 1 + \sum_{k, k \neq j} P_{ik} m_{kj}$$

ميزة المعادلة السهلة انك **هتعدد k** بس فيها بدل الـ n (يعني لو عندك في المسألة 3 states هتعدد 2 بس)... بس فيه تريكيات كمان في المعادلة مش هتشوفها غير بمثال عليها (اللي جاي ده) وهي ان **المعادلة recursive** يعني انت هتجيب الـ m اللي انت عايزها بدلالة نفس الـ m دي عادي.

5. مثال على الـ first-hitting time

$$P = \begin{bmatrix} \frac{1}{4} & \frac{3}{4} & 0 \\ 0 & \frac{1}{4} & \frac{3}{4} \\ \frac{1}{4} & 0 & \frac{3}{4} \end{bmatrix}$$

Q: In a Markov chain with state space $S = \{1, 2, 3\}$ and the following one-step transition matrix P , at state 1, find expected time until reaching state 3.

الحل:

هنا هو عايز الـ first-hitting time (m_{13})، قايلك من سكة جيب الـ time لحد ما توصل للـ state كذا) فإنـت ببساطة هتجـيـلـه المعـادـلـة بـتـاعـتـها وـتـمـشـيـ معـاهـا:

$$m_{13} = 1 + \sum_{k, k \neq j} P_{1k} m_{k3}$$

طبعـاً مش هوـصـيك انـك هـتـعـدـ الـ $k \in \{1, 2\}$ فـهـتـعـوـضـ بيـهـمـ فيـ الـ sumـ عندـكـ:

$$m_{13} = 1 + P_{11} m_{13} + P_{12} m_{23}$$

$$m_{13} = 1 + \frac{1}{4} m_{13} + \frac{3}{4} m_{23}$$

عشـانـ المـعـادـلـة recursiveـ لـقـيـتـ انـ الـ m_{13} (المـطلـوبـ بـتـاعـكـ) مـوـجـودـ فيـ الـطـرـفـينـ فـإـنـتـ هـتـخـلـيـهـمـ فيـ طـرـفـ واحدـ وـهـيـطـلـعـكـ بـدـلـالـةـ الـ m_{23} (معـادـلـةـ 1ـ):

$$\frac{3}{4} m_{13} = 1 + \frac{3}{4} m_{23}$$

كدة ممكن تتكرم وتجيب الـ m_{23} بنفس الطريقة (اللي هيطلع منها معادلة 2):

$$m_{23} = 1 + \sum_{k, k \neq j} P_{2k} m_{k3}$$

$$m_{23} = 1 + P_{21} m_{13} + P_{22} m_{23} = 1 + \frac{1}{4} m_{13} + \cancel{(0)} \cancel{m_{23}}$$

$$m_{23} = 1 + \frac{1}{4} m_{13}$$

ولو عوضت معادلة 2 في معادلة 1 هيطلعلك الحل بتاع m_{13} على طول ومبروك عليك المسألة:

$$\frac{3}{4} m_{13} = 1 + \frac{3}{4} \left(1 + \frac{1}{4} m_{13} \right)$$

$$\frac{3}{4} m_{13} = 1 + \frac{3}{4} + \frac{3}{16} m_{13}$$

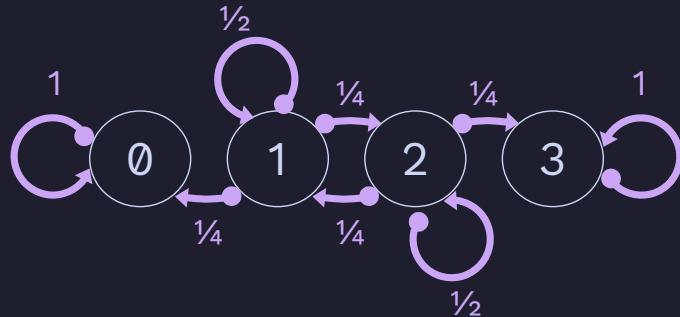
$$\frac{9}{16} m_{13} = \frac{7}{4}$$

$$m_{13} = \frac{28}{9}$$

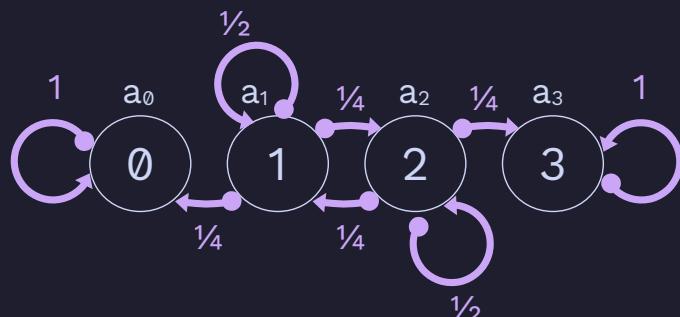
Lec7: First-step Analysis

طريقة كمان عشان نحسب ال absorbing probability

غير طريقة ال $R^{-1}Q$ فيه طريقة كمان عشان احسب ال absorbing probability وهي اني اخذ بعين الاعتبار انا بروح لأنهي absorbing state بالضبط... تعالى نشوف كدة نطبق عليها:



دلوقي انا ممكن احط رمز معين لال absorbing probability بتاعت ال states كلها وهنا عندي ال 0 وال 3 هما ال absorbing states بتوعي فهعمل ده لكل state منهم... ول يكن ان ال a_i يعني احتمالية اني اروح وابقي absorbed من i في ال 0 ... و b_i يعني بالعكس احتمالية اني اروح وابقي absorbed من i في ال 3 ... نبدأ بس بال a_0 بلاش نستعجل وحطها جنب كل state من اللي عندي:



هنا انت عندك ثوابت تتجاب بالبدويهيات: انا دايماً لو كنت في state 0 هفضل عندها في كل خطوة جاية... معنى كدة $a_0 = 1$, ولو كنت في state 3 رقم 3 استحالة اروح منها حتى لل 0 ... ومعنى كدة $a_3 = 0$

$$a_0 = 1, a_3 = 0$$

كدة بقى انت فاضلك تجيب a_1 و a_2 و دول هيطلعولك recursive معادلات وهنفهمها دلوقي... دلوقي انت لو في state رقم 1 مثلاً يبقي انت ممكن تروح اول خطوة بالعدد k states ايه بالضبط؟ 0 او 1 (في self-transition) او 2... اهي بقى كل absorbing probability ممكن احسبها بدلاة ال absorbing probabilities الثانية اللي هو ايه مجموع احتماليات اني ابقي absorbed من كل state من دول مضروبة في احتمالية اني اروح لال states دي من عندي:

$$a_i = \sum P_{ik} a_k$$

فهنيداً فهضر كل دول في بعضهم وهجم عليهم طبعاً:

$$a_1 = P_{10}a_0 + P_{11}a_1 + P_{12}a_2$$

$$a_1 = \frac{1}{4}(1) + \frac{1}{2}a_1 + \frac{1}{4}a_2 \rightarrow \frac{1}{2}a_1 = \frac{1}{4} + \frac{1}{4}a_2$$

نفس الكلام ممكن اعمله على الـ a_2 ... ركز انا ممكن اروح من state رقم 2 لـ 1 ولـ 2 (في self-transition :3)

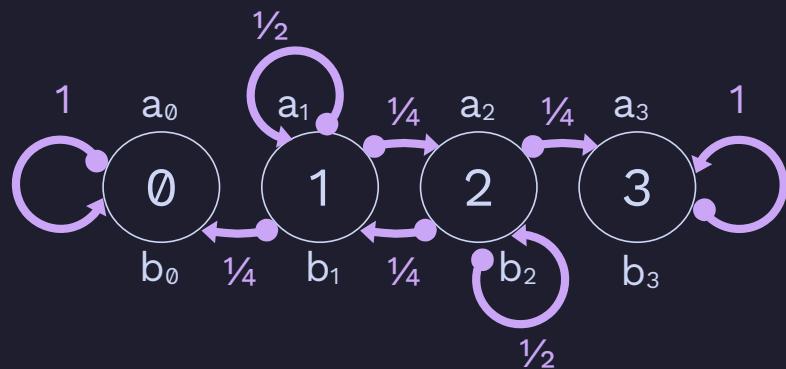
$$a_2 = P_{21}a_1 + P_{22}a_2 + P_{23}a_3$$

$$a_2 = \frac{1}{4}a_1 + \frac{1}{2}a_2 + \frac{1}{4}(0) \rightarrow \frac{1}{2}a_2 = \frac{1}{4}a_1$$

كدة بقي معايا معادلتين احلهم مع بعض وكالعادة هحرقلك عليك حلهم:

$$a_1 = \frac{2}{3}, a_2 = \frac{1}{3}$$

طب ده وبالنسبة للـ a_i ... ايه بقي الوضع بالنسبة للـ b_i ؟ طبعاً انت ممكن تكرر نفس القصة الطويلة بالنسبة للـ b_i بس حرفياً طالما عندنا اتنين اتنين absorbing بس يعني احتمالية اني ابقي absorbed في state بتساوي 1 - اني ابقي absorbed في state الثانية ... فلو قولنا ان كل b_i معناها absorbing probability بس في state الثانية (او ان كل a_i قصادها بالضبط b_i زيها):



: $b_i = 1 - a_i$

$$b_i = 1 - a_i \rightarrow b_0 = 0, b_3 = 1, b_1 = \frac{1}{3}, b_2 = \frac{2}{3}$$

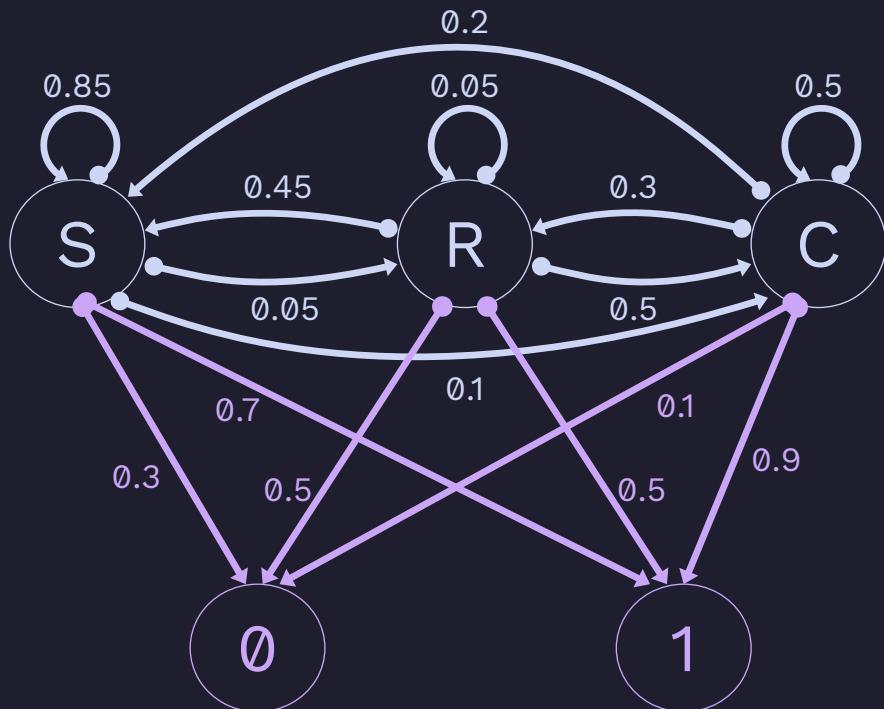
Lec8: Hidden Markov Model and Forward Algorithm

1. ال hidden Markov model :

دلوقي بدل ما في ال Markov model العادي بتاعنا احتمالات تبقي عندي ما بين states جاهزة وانا ابقي في كل state اتنقل منها وخلاص لأ بقي عندي احتمالات تانية بتاعها مربوطة بال states دي... وممكن يبقي ده بس اللي ظاهري وممكن اتعامل معاه (ويبيقي ده اسمه ال hidden Markov model واختصاره HMM).

في مثال الطقس الجميل بتاعنا... ممكن احتمالات اي اروح من كل حالة طقس والثانية متباش ويبان منها بس احداث مربوطة بيها بامتحالات مخصوصة زي ان الجو كان حلو ساعتها ولا لا... بنسمي الاحداث دي برضه **observable events** او **الاحداث الظاهرة** (وحالات الطقس بتاعتنا في الحالة دي ممكن نسميهem **hidden states** او حالات مخفية بتبان بس من ال observable events او ال observations بمعنى اصح).

لو جيت رسمت ال Markov chain بتاعنا بتاع الطقس مفروض ورسمت معاه برضه اتنين observable events نرقمهم 0 و 1 (قول مثلاً 1 يعني الجو كان حلو) فممكنا اطلع من كل state من اللي عندي سهم بامتحال معين لكل observable event :



اه ال chain كلها بقى شكلها يخص بس ركز معايا ان فيه اسهم رايحة من غير ما ترجع من ال states بتاعتي S و R و C و للي معايا ال 0 والا 1 وكإنها بتقولي احتمالات ان كل event من دول يطلع من (او يتربط بـ) كل ال states ...

احتمالات زي دي بقى بتتحط في matrix جديدة غير الـ P اسمها الـ E او مصفوفة الانبعاثات (وبنرمزلها بـ E):

$$E = \begin{matrix} & \begin{matrix} 0 & 1 \end{matrix} \\ \begin{matrix} S \\ C \\ R \end{matrix} & \begin{bmatrix} 0.3 & 0.7 \\ 0.1 & 0.9 \\ 0.5 & 0.5 \end{bmatrix} \end{matrix}$$

دي كل اللي فيها بتبقى احتمالات زي الـ P , يعني لو قولنا مثلاً في تايم $t=1$ احتمال ان event رقم 0 يطلع من state رقم C (ربط الـ state نفسه يعني observation نفسها وبنرمزلها بـ o_1) هيقي كدة:

$$P(o_1=0 \mid X_1=C) = P(0 \mid C) = e_C(0) = 0.1$$

كمان احتمالية هنتعرف عليها (او حتى هنفتركها) وهي احتمالية $sequence$ او سلسلة معينة من الـ $states$ زي لما اقولك ايه احتمالية اني في اول وقت هعدي علي S وبعديها علي طول هعدي علي R وبعديها علي طول هعدي علي C :

$$P(SRC)$$

دي سهلة وبسيطة هفكها زي ما بفك اي and زي ما كنت بعمل:

$$\begin{aligned} P(SRC) &= P(X_1=S, X_2=R, X_3=C) \\ &= P(X_1=S)P(X_2=R \mid X_1=S)P(X_3=C \mid X_2=R) \\ &= P(X_1=S)P(R \mid S)P(C \mid R) = \pi_1 P_{SR} P_{RC} \end{aligned}$$

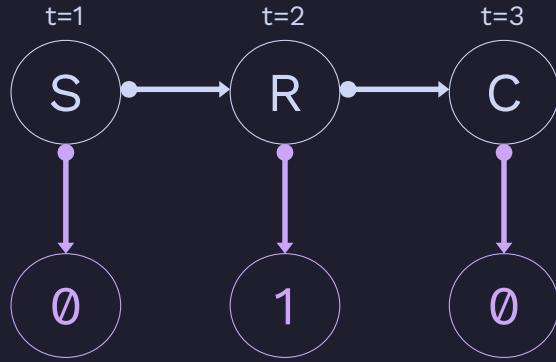
المشكلة بقى لو اتربط بكل واحدة فيهم $observable event$ بيها:

$$P(010, SRC \mid \lambda)$$

مبديئاً بس يعني ايه الـ λ هنا؟ دي معناها بمعلومية الـ P والـ E والـ π مع بعض:

$$\lambda = (P, E, \pi)$$

نرجع لمثالنا تاني وخلينا نرسمه علي شكل diagram عالخفي:



ده يعتبر ال sequence بتعدي البداية فيه عندي من اول $t=1$ بدأت بال S واتربط بيها event رقم 0 , بعدين روحت من S لـ R واتربط بال R معايا event رقم 1 , بعدين روحت من R لـ C واتربط بال C معايا event رقم 0 . ببساطة طالما كل احتمالية من دول بما فيهم احتماليات كل observation بيحصلوا مع بعض (فيه بينهم كلهم and اصلاً) يبقى ممكن اضربهم مع بعض عادي:

$$\begin{aligned}
 & P(010, SRC \mid \lambda) \\
 & = P(X_1=S)P(0|S)P(R|S)P(1|R)P(C|R)P(0|C) \\
 & = P(SRC)P(0|S)P(1|R)P(0|C) \\
 & = P(SRC)e_S(0)e_R(1)e_C(0)
 \end{aligned}$$

2. ال forward algorithm وعماليه:

طب انا لو عايز مثلاً اجيip كل احتماليات ان ال observations نفسها تحصل (مش مربوطة بـ hidden states زي مثلاً:

$$P(010 \mid \lambda)$$

مسائل زي دي بنسميه evaluation problems او مسائل التقييم اني بقيم نوع احتماليات معين (بمعلومية ال λ بتعدي ال P وال E وال π زي ما قولنا)... الشكل العام بتاعهم كدة (لمة ال 0 دول زي ما قولتلك دول ال observations وبجيip احتمالية انهم يحصلوا مع بعض):

$$P(o_1, o_2, \dots, o_T \mid \lambda) = P(o_{1:T} \mid \lambda)$$

عموماً يعني حلهم بيكون بخوارزميات زي ال forward algorithm وال backward algorithm هناخد منهم دلوقتي ال forward algorithm

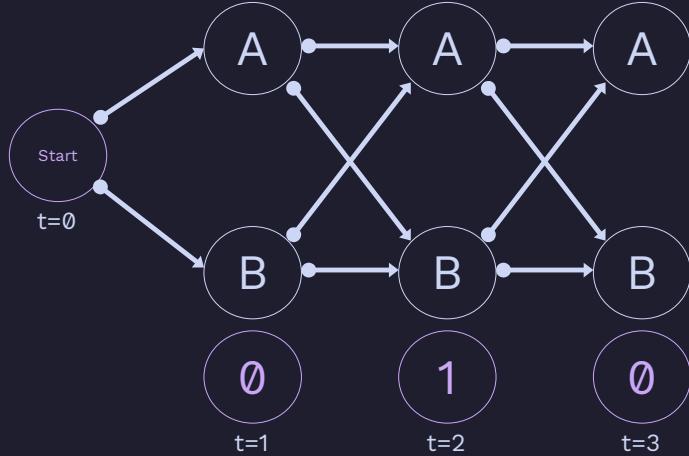
Q: For the event space $S = \{A, B\}$ and the observable events $O = \{0, 1\}$, the following values for P , E , and π are given.

Evaluate $P(010 | \lambda)$ using the forward algorithm, where $\lambda = (P, E, \pi)$.

$$P = \begin{bmatrix} 0.99 & 0.01 \\ 0.01 & 0.99 \end{bmatrix} \quad E = \begin{bmatrix} 0.8 & 0.2 \\ 0.1 & 0.9 \end{bmatrix} \quad \pi = \begin{bmatrix} 0.99 & 0.01 \end{bmatrix}$$

الحل:

انت عندك 3 events اللي عايز تقيمهم ف ساعتها هتعمل 3 خطوات (البداية ومضروب فيهم ال transitions واحدة بواحدة)... خليني ارسم انا قصدي ايه:



انا شلت الأسماء بتاعت event عشان التركيز دلوقتي على ال states بتاعتي بس افهم انت ان كل state اوتوماتيك مربوط بسهم لل event اللي قصاده.

دلوقتي انت بدايتك عند ال Start و هتروج منه ل $t=1$ فممك ابدأ مشيت في سكتين يا اما لل A او لل B ... كدة عندي احتمال كل سكة فيهم هو احتمال اني ابدأ منهم (يعني كدة π بتاعت كل state مربوط في ال event اللي مربوط بيها (هتفق علي ان الاحتمالات دي بنزلها بـ α_1 لكل state منهم):

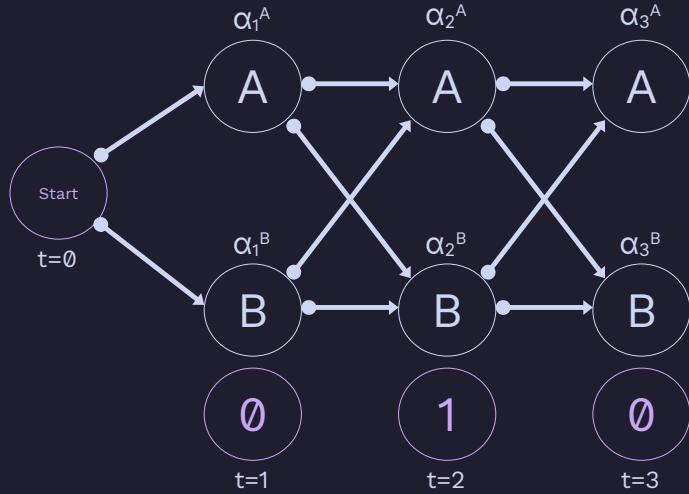
$$\alpha_1^A = P(X_1 = A) P(0|A) = \pi_A e_A(0) = 0.99(0.8) = 0.792$$

$$\alpha_1^B = P(X_1 = B) P(0|B) = \pi_B e_B(0) = 0.01(0.1) = 0.001$$

دلوقتي انت مطلوب منك تمشي في كل تباديل السكك منهم لحد ما توصل ل α_3^A او α_3^B في اخرهم (عشان اخر التایم بتاعي $t=3$ ومعنديش غير اتنين states) عشان الاحتمال اللي عايزينه ($P(010 | \lambda)$ بيساوي مجموعهم:

$$P(010 | \lambda) = \sum_i \alpha_3^i = \alpha_3^A + \alpha_3^B$$

هنا بقى انا هرسم تاني نفس ال diagram بس هحط عليها كل α عندي اوضح بس
متش اكتر:



طب دلوقتي معانا α_1^A و α_1^B ... ازاى نجيب الباقي؟ نبدأ ب α_2^A مثلاً... فيه سكتين انا
ممکن اروح فيهم ليها واحدة من α_1^A وواحدة من α_1^B ... طب ماشي احتمال كل سكة
فيهم يعني احتمال اللى فيها (كل α معتمدة على كل اللى قبلها) مضروب في
احتمال اني اروح في ال states للسكة دي (من A ل A او من B ل A) مثلاً... احتمالات
ال transitions اللي من ال P عادي) مضروب فيه احتمال ال event اللي مراد فيه...
هنا في α_2^A انت سكك من α_1^A (رايح من A) و α_1^B (رايح من B) لـ :

$$\alpha_2^A = \alpha_1^A P(A|A)P(1|A) + \alpha_1^B P(A|B)P(1|A)$$

$$= \alpha_1^A P_{AA} e_A(1) + \alpha_1^B P_{BA} e_A(1)$$

$$= 0.792(0.99)(0.2) + 0.001(0.01)(0.2) = 0.1568$$

نفس الكلام هعمله مع α_2^B (السكتين بتوعي برضه من α_1^A و α_1^B بس المرادي لـ B):

$$\alpha_2^B = \alpha_1^A P(B|A)P(1|B) + \alpha_1^B P(B|B)P(1|B)$$

$$= \alpha_1^A P_{AB} e_B(1) + \alpha_1^B P_{BB} e_B(1)$$

$$= 0.792(0.01)(0.9) + 0.001(0.99)(0.9) = 0.008$$

كدة فاضلنا α_3^A و α_3^B (اللي هما اخرk) ودول هيتجابوا بنفس الطريقة بالظبط (خلي بالك من تبديلة الـ α وتبديلة الـ $events$ هترجع تاني لـ event رقم 0):

$$\alpha_3^A = \alpha_2^A P(A|A)P(0|A) + \alpha_2^B P(A|B)P(0|A)$$

$$= \alpha_2^A P_{AA} e_A(0) + \alpha_2^B P_{BA} e_A(0)$$

$$= 0.1568(0.99)(0.8) + 0.008(0.01)(0.8) = 0.1242$$

$$\alpha_3^B = \alpha_2^A P(B|A)P(0|B) + \alpha_2^B P(B|B)P(0|B)$$

$$= \alpha_2^A P_{AB} e_B(0) + \alpha_2^B P_{BB} e_B(0)$$

$$= 0.1568(0.01)(0.1) + 0.008(0.99)(0.1) = 0.0009$$

برضه كدة انت فهمت لو عايز معادلة واحدة او قاعدة عامة تربط كل α باللي قبلها خد المعادلة دي (هتلaciوني اشتغلت بيها في السكرنة في تاني سطر من كل حسبة α عموماً):

$$\alpha_{t+1}^j = \sum_i \alpha_t^i P_{ij} e_j(o_{t+1})$$

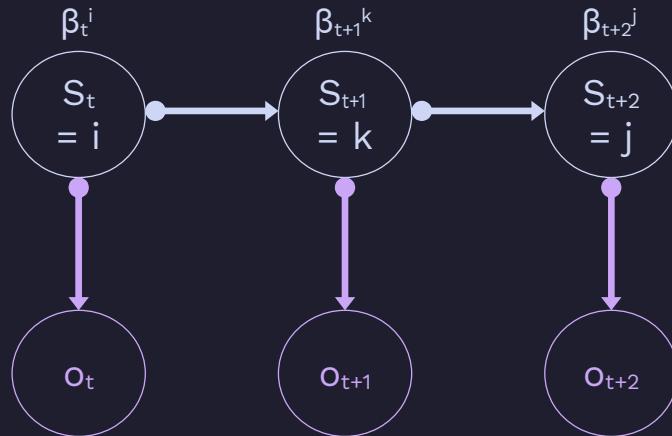
وبس كدة طالماوصلت لأخرk بيبقى خلصت (النواتج كلها متقربة فبعيد سيكاك عن الناتج الصح 0.1252 لو لسة مأخذتش بالك):

$$P(010 \mid \lambda) = \alpha_3^A + \alpha_3^B = 0.1242 + 0.0009 = 0.1251$$

Lec9: Backward Algorithm

1. اثبات ال backward algorithm

زي ما قولت قبل كدة فيه طريقة تانية عشان احل مسائل ال evaluation problems وهي ال backward algorithm ... دى تعتبر نفس ال forward algorithm بس بкам تغيير هيفرقوا مع الخوارزمية دى بالذات بس الأول هحتاجك تعرف اثبات مهم الأول:



في نفس الرسمة بتاعت اي sequence دلوقتي الرموز عندي اتغيرت بدل كل α معايا بدلها β وكمان الحسبة معكوسه اني دلوقتي عايزة اجيب احتمالية الأول بدلاة اللي جاي:

$$\beta_t^i = P(o_{t+1:T} \mid S_t = i) = \sum_k P(o_{t+1:T}, S_{t+1} = k \mid S_t = i)$$

هنا اللي جاي بعد β_t^i اللي عايزة احسبها باقي events sequence ال اللي جاي $(o_{t+1:T} = o_{t+1}, o_{t+2}, \dots, o_T)$ وطبعاً ده اخر تايم معايا) وال اللي هروحلها من عند β_t^i (ال اللي هفكها ل k كالعادة) وال اللي كل واحدة منهم ليها β_{t+1}^k بتاعتتها. دلوقتي انت ممكن تفك β_t^i برا ال $o_{t+1:T}$ وال اللي هيتبقي معاك ساعتها $: o_{t+2:T}$

$$= \sum_k P(o_{t+2:T}, o_{t+1}, S_{t+1} = k \mid S_t = i)$$

هفك ال and اللي بين ال $o_{t+2:T}$ والباقي:

$$= \sum_k P(o_{t+2:T} \mid \cancel{o_{t+1}}, S_{t+1} = k, \cancel{S_t = i}) P(o_{t+1}, S_{t+1} = k \mid S_t = i)$$

انا كنسلت $S_t = i$ طبعاً عشان تايم اقل من $t+1 \dots t+1$... بس ليه كنسلت o_{t+1} ? عشان ببساطة كل event يعتبر independent او مستقل عن الثاني o_{t+1} ف ملحوش اي علاقة بـ $o_{t+2:T}$.

عموماً ده اللي معانا حتى الأن:

$$\beta_t^i = \sum_k P(o_{t+2:T} | S_{t+1}=k) P(o_{t+1}, S_{t+1}=k | S_t=i)$$

تاني probability مشن هعرف افكتها تاني زي اي and كنت بعملها عشان نفس التايم...
بس لو تركز شوية هتلacci اني بجيip احتمالية ال **observation** من k لـ o_{t+1} بدلاة
ال **transition** بتاعي من i لـ k (يعني $P_{ik} e_k(o_{t+1})$). اول probability بقى هتلacciها هي
هي زي تعريف ال β_t^i بتاعتي بس بدل ال $t+1$ هتبقي $t+2$ وبدل ال a عندي k ... فكدة انا
من غير ما احس طلعت ال β_{t+1}^k :

$$\beta_t^i = \sum_k \beta_{t+1}^k P_{ik} e_k(o_{t+1})$$

كدة اثباتك خلص وزي الفل... عشان اخلي القانون بقى زي القاعدة العامة بتاعت α
(وعشان تفهمه بالاً والز اللي متعود عليهم) يدوبك هبدل كل k بالز:

$$\beta_t^i = \sum_j \beta_{t+1}^j P_{ij} e_j(o_{t+1})$$

2. ال **backward algorithm** وعماليه:

نرجع نطبق بقى علي نفس المسألة بس بال **backward** عشان فاضلي كام حاجة بس
لازم اوضحهم:

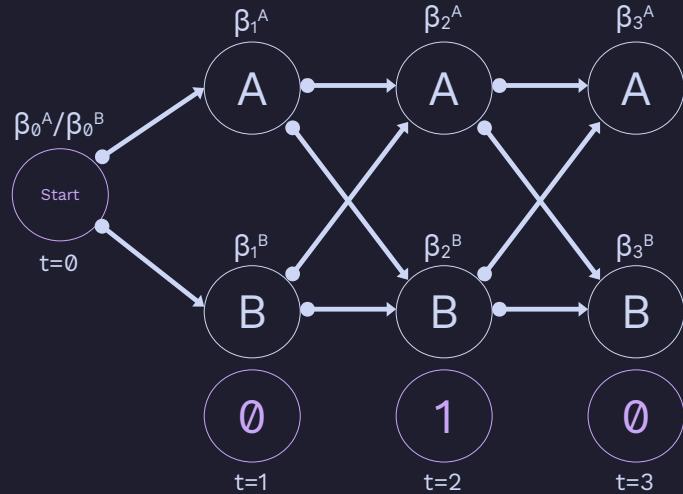
Q: For the event space $S = \{A, B\}$ and the observable events $O = \{0, 1\}$,
the following values for P , E , and π are given.

Evaluate $P(010 | \lambda)$ using the backward algorithm, where $\lambda = (P, E, \pi)$.

$$P = \begin{bmatrix} 0.99 & 0.01 \\ 0.01 & 0.99 \end{bmatrix} \quad E = \begin{bmatrix} 0.8 & 0.2 \\ 0.1 & 0.9 \end{bmatrix} \quad \pi = \begin{bmatrix} 0.99 & 0.01 \end{bmatrix}$$

الحل:

برضه هرجع ارسم نفس الرسمة بتاعتي بس بدل كل α هحط β :



دلوقيتي انا هرجع من الآخر للأول وهنا هبدأ من β_3^A و β_3^B ... بما اني انا متأكد ان sequence بتاعتي ايًّا يكن ايه هي تمت فبنخلي كل واحد فيهم بيساوي 1:

$$\beta_3^A = 1, \beta_3^B = 1$$

انا بقى عايز ايه عموماً من مسألتي؟ اجيب الـ $P(010 | \lambda)$ بتاعتي وهنا انا برجع خالص لحد الـ Start يعني اجيب لحد β_0^A والـ β_0^B وهقولك ليه مش مجموعهم بعدين (ممك تكون اخد بالك اني حطيتهم فوق الـ Start من بدري):

$$P(010 | \lambda) = \beta_0^A = \beta_0^B$$

واحدة واحدة نبدأ نجيب الـ β_2^A و β_2^B وهنبدأ بالـ β_2^A ... هنا زي ما انت عارف برجع من ورا لقدم بمعني ده احتمال كل سكة انا رايحلها (كل β معتمدة على كل الـ β اللي بعديها) مضروب في احتمال اني اروح في الـ states للسكة دي (من A لـ A او من A لـ B مثلًا... احتمالات الـ transitions اللي من الـ P عادي) مضروب فيه احتمال الـ event اللي مربوط في الـ state الجاية ... في β_2^A مثلًا انت سكك لـ β_3^A (رایح لـ A) و β_3^B (رایح لـ B) من الـ A:

$$\begin{aligned} \beta_2^A &= \beta_3^A P(A|A) P(0|A) + \beta_3^B P(B|A) P(0|B) \\ &= \beta_3^A P_{AA} e_A(0) + \beta_3^B P_{AB} e_B(0) \\ &= 1(0.99)(0.8) + 1(0.01)(0.1) = 0.793 \end{aligned}$$

هتكرر نفس الكلام علي β_2^B (سكي برضه ل β_3^A ول β_3^B بس المرادي من الـB)

$$\begin{aligned}\beta_2^B &= \beta_3^A P(A|B)P(0|A) + \beta_3^B P(B|B)P(0|B) \\ &= \beta_3^A P_{BA} e_A(0) + \beta_3^B P_{BB} e_B(0) \\ &= 1(0.01)(0.8) + 1(0.99)(0.1) = 0.107\end{aligned}$$

هنا بقى مش هوصيك اني اخش علي طول باللي معايا علي β_1^A و β_1^B :

$$\begin{aligned}\beta_1^A &= \beta_2^A P(A|A)P(1|A) + \beta_2^B P(B|A)P(1|B) \\ &= \beta_2^A P_{AA} e_A(1) + \beta_2^B P_{AB} e_B(1) \\ &= 0.793(0.99)(0.2) + 0.107(0.01)(0.9) = 0.158 \\ \beta_1^B &= \beta_2^A P(A|B)P(1|A) + \beta_2^B P(B|B)P(1|B) \\ &= \beta_2^A P_{BA} e_A(1) + \beta_2^B P_{BB} e_B(1) \\ &= 0.793(0.01)(0.2) + 0.107(0.99)(0.9) = 0.0969\end{aligned}$$

وبعديهم او β_0^B اللي هما اخري (الاتنين نفس القيمة والحسابه عموماً)... بس ركز معايا هنا انك اصلاً بادئ من الـstart بمعنى ان احتماليتك هنا هتبقي الـπ بدل الـP فكدة يعتبر عاملها حسبة مخصوص نوعاً ما:

$$\begin{aligned}P(010 \mid \lambda) &= \beta_0^A = \beta_0^B \\ &= \beta_1^A P(X_0=A)P(0|A) + \beta_1^B P(X_0=B)P(0|B) \\ &= \beta_1^A \pi_A e_A(0) + \beta_1^B \pi_B e_B(0) \\ &= 0.158(0.99)(0.8) + 0.0969(0.01)(0.1) = 0.1252\end{aligned}$$

ليه برضه β_0^A و β_0^B بيساواوا بعض؟ زي ما قولتلك قبل كدة كل β معتمدة علي السكتين اللي قدامها... فالسكتين بتوع β_0^A و β_0^B عشان معتمدين علي الـπ بتاعت الـsequence كلها بدل الـP بتاعت state واحدة بس فهي كدة متساوية عالسكتين.

3. مقارنة خفيفة بين الـ **backward** والـ **forward**:

دلوقيتي يمكن الخوارزميتين لما كل واحد فيهم اتشرح لوحده يلخبط جامد... فعموماً هحطلك كل الفروقات ما بينهم وامثلة علي كله في صفحة واحدة. لاحظ ان كل حاجة بغيرها علي كل الـ states (زي الـ a بالضبط) حاططها بلون مختلف وتحتبيها خط.

الـ **forward**:

- بمشي من الأول (الـ Start) لقدم.
- معادلة البداية لكل α_1 :

$$\alpha_1^i = \pi_i e_i(o_1) \rightarrow \alpha_1^A = \pi_A e_A(0), \alpha_1^B = \pi_B e_B(0)$$

- معادلة الـ forward لكل α_{t+1} (بدلاة اللي قبلها α_t):

$$\alpha_{t+1}^j = \sum_i \alpha_t^i P_{ij} e_j(o_{t+1})$$

$$\rightarrow \alpha_2^A = \alpha_1^A P_{AA} e_A(1) + \alpha_1^B P_{BA} e_A(1)$$

- معادلة النهاية (بجمع كل α_T مع بعضهم):

$$P(o_{1:T} | \lambda) = \sum_i \alpha_T^i \rightarrow P(010 | \lambda) = \sum_i \alpha_3^i = \alpha_3^A + \alpha_3^B$$

الـ **backward**:

- بمشي من الآخر لورا (لحد الـ start).
- معادلة البداية لكل β_T :

$$\beta_T^i = 1 \rightarrow \beta_3^A = 1, \beta_3^B = 1$$

- معادلة الـ backward لكل β_t (بدلاة اللي بعدها β_{t+1}):

$$\beta_t^i = \sum_j \beta_{t+1}^j P_{ij} e_j(o_{t+1})$$

$$\rightarrow \beta_2^A = \beta_3^A P_{AA} e_A(0) + \beta_3^B P_{AB} e_B(0)$$

- معادلة النهاية (حسبة مخصوص للـ β_0):

$$P(o_{1:T} | \lambda) = \beta_0^i = \sum_j \beta_1^j \pi_j e_j(o_1)$$

$$\rightarrow P(010 | \lambda) = \beta_0^A = \beta_0^B = \beta_1^A \pi_A e_A(o_1) + \beta_1^B \pi_B e_B(o_1)$$

وبس كدة المحتوي خلص...

Fin.

واه تذكرة خفيفة ان كل دي مجهدات فردية (من اول تجميع المحتوي لتنظيمه وتنسيقه لحد تصحيحه ومراجعته وتحسينه بشكل دوري) ومهم في اي ملخص بعمله انه يطلع بشكل consistent ومتناقض علي قد ما اقدر ويبيقي ملخص ومرجع نضيف وبالمسطورة ومهم ليها قبل ما يبقي ليكم... فأعذروني لو فيه اي غلطة ولو صغيرة حصلت ولقيتوها وغابت عن عيني وأخذتش بالي منها (برضه براجع الملخص بشكل دوري وبحاول اتأكد انه مفيهوش غلطات كل فترة وقت).